

学校代码：10270

分类号：TN92

学号：152201059

上海师范大学

硕士学位论文

基于聚类的 DTI 图像分割与三维重建

学 院： 信息与机电工程

专 业： 通信与信息系统

研 究 方 向： 图像处理与流媒体通信

研究生姓名： 房博文

指 导 教 师： 张相芬

完 成 日 期： 2018 年 4 月

摘要

弥散张量成像 (Diffusion Tensor imaging DTI) 是在弥散加权的基础上发展而来的新型成像技术, DTI 可以提供其他成像方式所不能提供的独特信息, 且具有非侵入和不需要造影剂等优点, 是目前无创辨识活体脑白质微细结构的唯一技术。DTI成像可以进行脑组织在分子水平上的病变检测, 以辅助临床诊断。由于某些疾病(如脑缺血、中风、老年痴呆及精神分裂等)的发病早期, 脑组织部分会出现相应的水分子扩散异常, 而常规核磁共振成像 (Magnetic Resonance Imaging MRI) 等设备难以检测到这种变化。因此, 扩散张量成像后, 对DTI 数据中组织区域的提取与分割, 再利用三维重建的方法对其进行绘制, 这样可以为医学辅助诊疗提供更好的分析手段。本文主要做了以下研究:

1. 提出了改进的模糊C均值聚类算法(Fuzzy C-means FCM), 模糊C均值聚类算法在初始聚类中心点的选取上为随机选取, 由于最终的聚类结果对初始聚类中心点有一定的依赖性, 为了避免随机的聚类中心点影响最终的聚类结果, 本文提出了FCM与最大最小距离结合应用的算法, 在经典的FCM基础上引入最大最小距离, 通过实验数据集对改进后的模糊C均值聚类算法进行了有效的验证。实验结果证明, 改进后的模糊C均值分割脑组织可以得到更光滑的边缘信息, 错误分割区域减少, 分割的准确性得到了提高。

2. 提出了自适应的均值漂移算法(Mean Shift MS), 均值漂移算法的基本思路是搜索所给样本空间中样本点最密集的区域, 沿着密度增大的方向漂移到局部密度最大值处。不同于其他聚类算法, 漂移寻找局部最大值是不断迭代的过程, 所以不需要先验知识。但是传统均值漂移算法的带宽为固定值, 无法根据像素点的分布情况进行自动调整, 本文提出了自适应的均值漂移算法, 通过重新定义窗函数, 结合像素的概率密度函数, 使像素点不同的概率密度适用不同的带宽值, 在图像分割中分割效果得到了改善。

3. 进行了胼胝体的三维绘制。三维重建是对医学图像分割更直观的体现, 从三维的角度对分割的医学组织进行展示。面绘制作为一个重要的绘制算法, 通过对处理的数据设置等值面, 然后对等值面进行渲染。可视化类库 (Visualization Toolkit VTK) 作为一个开源的工具, 为三维重建在手术仿真, 模拟解剖, 医学诊断等领域提供了重要的平台。本文通过结合三维可视化的流程对VTK中类库的层次结构进行了研究, 并基于面绘制算法, 利用VTK结合Visual Studio 2010 开发平台实现了对脑胼胝体的三维绘制, 实验结果取得了较好的三维呈现效果。

关键词: 扩散张量成像; 图像分割; 聚类算法; 三维重建; 可视化类库

Abstract

Diffusion Tensor imaging(DTI) is a new type of imaging technique which is based on Diffusion weighted imaging, DTI can provide unique information which can not be provided by other imaging modalities, and has the advantages of non-invasive and no contrast agents. It is the only technique for non-invasive identification of the fine structure of living brain white matter at present. DTI imaging can be used to detect the pathological changes of brain tissue at the molecular level so as to assist in clinical diagnosis. Due to the early onset of certain diseases, such as cerebral ischemia, stroke, dementia, and schizophrenia, some of the water molecules in the brain appear to be abnormally diffused, whereas conventional MRI devices are difficult to detect this change. The extraction and segmentation of tissue regions in DTI data and the method of three-dimensional reconstruction are used to draw them, so as to provide better analytical means for medical auxiliary diagnosis and treatment. Therefore, the following research is mainly done in this paper:

1. An improved fuzzy C mean clustering algorithm is proposed, the fuzzy C-means clustering algorithm randomly selects the center point of the initial cluster. Because the final clustering result has a certain dependence on the initial clustering center point, the random clustering center point will not affect the final clustering. As a result, the combination of FCM and maximum-minimum distance algorithm is proposed in this paper. The maximum and minimum distances are introduced on the basis of classical FCM, and the improved fuzzy C-means clustering algorithm is validated by the experimental data set. The experimental results show that the improved fuzzy C-means segmentation can obtain more smooth edge information, the wrong segmentation area is reduced, and the segmentation accuracy is improved.

2. An adaptive mean drift algorithm is proposed , the basic idea of the mean shift algorithm is to search for the densest area of sample points in the given sample space and drift to the local density maximum along the direction of increasing density. Unlike other clustering algorithms, drifting to find the local maximum is a continuous iterative process, so no prior knowledge is required. However, the bandwidth of the traditional mean shift algorithm is a fixed value and cannot be automatically adjusted according to the distribution of the pixel points. This paper proposes an adaptive mean shift algorithm. By redefining the window function and combining the probability density

function of the pixels, the pixel points are different. Probability density applies to different bandwidth values, and the segmentation effect is improved in image segmentation.

3. Three - dimensional drawing of corpus callosum was performed, the three-dimensional reconstruction is a more intuitive embodiment of medical image segmentation, and the segmentation of medical organizations from a three-dimensional point of view. Surface rendering is an important rendering algorithm. By setting the contour surface of the processed data and rendering it on the peer surface, the final 3D rendering is achieved. Visualization Toolkit VTK, as an open source tool, provides an important platform for 3D reconstruction in surgical simulation, simulation anatomy, medical diagnosis and other fields. In this paper, we have studied the class library and hierarchical structure in VTK by combining the 3D visualization process. Based on the surface rendering algorithm, we have realized the 3D rendering of corpus callosum by combining VTK with Visual Studio 2010 development platform, the experimental results obtained better 3d rendering effect.

Key Words: Diffusion tensor imaging; image segmentation; clustering algorithm three-dimensional reconstruction ; visualization toolkit

目录

摘要	I
Abstract	II
目录	IV
第 1 章 绪论	1
1.1 课题研究的背景和意义.....	1
1.2 国内外研究现状分析.....	2
1.3 研究目标及主要研究内容	3
1.4 本论文的各章节安排	4
第 2 章 DTI 成像原理分析.....	5
2.1 扩散成像.....	5
2.2 扩散张量.....	6
2.3 各向异性参数的测度	9
2.4 本章小结.....	10
第 3 章 图像分割与模糊 C 均值算法	12
3.1 图像分割概述.....	12
3.2 区域分割算法.....	13
3.2.1 阈值分割算法	13
3.2.2 区域生长与分裂合并	15
3.5 DTI 图像分割步骤及流程.....	19
3.6 实验结果及讨论	20
3-7 本章小结.....	22
第 4 章 基于带宽的均值漂移算法	24
4.1 均值漂移算法.....	24
4.1.1 初始均值漂移算法	24
4.1.2 扩展的均值漂移算法	25
4.2 改进的均值漂移算法.....	27
4.2.1 自适应带宽	27
4.2.2 新均值偏移向量参数的计算	27
4.3 基于改进算法的 DTI 图像分割	28

4.4 实验结果与分析	28
4.5 本章小结	31
第 5 章 DTI 图像的三维重建	32
5.1 三维重建的基本过程	32
5.2 可视化类库 VTK	33
5.2.1 VTK 简介	33
5.2.2 VTK 类库组成介绍	33
5.2.3 VTK 可视化流程	34
5.3 CMAKE 与 VTK 配置	36
5.3.1 CMAKE 简介	36
5.3.2 VTK 的配置过程	37
5.4 三维重建的基本方法	39
5.4.1 等值面绘制	39
5.5 重建过程及结果	43
5.5.1 MC 算法重建过程	43
5.5.2 三维重建结果	45
5.6 本章小结	47
第 6 章 总结与展望	48
参考文献	50
攻读学位期间取得的研究成果	54
致谢	55

第1章 绪论

1.1 课题研究的背景和意义

DTI^[1]作为一种不同于传统成像的技术,其通过反映人体组织内分子的运动状况,在加权成像基础上能够呈现出更加详细的组织信息,能够给医学工作者和研究员带来更好的理论研究。扩散张量成像在对多种脑疾病的研究和处理上都显示出了独特的优点,比如脑梗死和肿瘤等,可以提供其他成像方式所不能提供的独特信息,能够更加丰富地呈现出脑组织内部微观信息。

DTI具有非侵入优点,其通过反映水分子在结构内部的扩散程度,从而反映出神经纤维束的具体走向和结构信息,无论是在理论探索,还是在临床方面都成为了研究的热点,显示出了很好的应用前景。

利用分割技术对DTI图像进行处理,将图像中的特定区域进行提取,医生或者研究者能够对人脑的解剖结构进行有效地研究和分析。首先,通过图像分割可以获取特定部位的病理信息,为后续的诊断提供一定的客观依据;其次,可以对图像的信息进行有效地管理,通过图像的分割,可以对不同的区域进行分类取舍;再次,可以进行参数的测量,通过对特定区域几何、病理等参数的测量,可以建立相应的结构数据库;最后,可以为三维重建提供前提条件,利用对标量图像分割得到的特定区域,可以利用三维重建方法对多层的二维图像进行重建,从三维的角度对人体结构进行观察和分析。

三维重建对分割后的感兴趣区域进行重建提供了一个更加立体逼真的效果。三维重建技术通过对二维断层序列分割得到的数据进行绘制并投影到视平面上,医生或者研究者可以实现对组织信息更好地交互,同时对该组织有更加立体的认知,并实现对该组织定性和定量的分析。现实生活中,限于仪器设备的因素,医生往往对断层图像序列中的信息进行空间想象建模,重建的效果并不会非常理想并且难度很大,三维重建技术的出现很好地解决了这一问题。此外,该技术具有一些实际的操作场景:1),可为医学影像实现数字化的形式,现在大部分医院对人体组织信息成像的载体为胶片形式,不但在存储方面存在困难,并且开销方面也不容小觑,所以在最终成像方面实现数字化管理在医院的发展上面也具有一定的推动作用。2),三维重建在虚拟手术操作方面也发挥着重大的作用,在临床医学实践领域,医生可以通过三维重建技术对人体组织模拟程度达到实际手术和实践的需求。所以从长远来看,三维重建发挥着意义非凡的现实作用。

1.2 国内外研究现状分析

人脑DTI图像作为一种特殊的MRI医学图像,对其成像进行研究的过程中,分割作为一个重要的方向受到了很多学者的重视,鉴于其在现实中的应用价值,国内外研究者在此方面做了许多不同的研究和改进。

Ali^[2]等人利用FCM算法在对人脑图像进行分割,首先利用形态学金字塔对预处理的多分辨图像和原始图像进行融合,再通过FCM算法对人脑图像进行分割,最终实验结果的准确率得到了提高。Pei^[3]等人将密度引入模糊C均值算法之中,通过计算样本集的密度,并使用密度值的大小来反应该样本点的重要性,利用数据点之间的密度关联程度去决定最初聚类中心。Ariyo^[4]等人论文中提出sFCMKA算法,该算法结合K均值算法和FCM算法,其中FCM算法引入了空间信息,算法先利用模糊C均值分割脑组织信息,然后再利用K均值算法去分割不重叠的脑组织,最终取得了比较好的实验效果。

张辉^[5]利用FCM对双水平集模型进行了处理,即对其进行了初始化操作,该算法充分利用了图像中的边缘信息,因此在一定程度上减少了噪声的影响。但是该算法在初始位置的选取上存在着特殊性,还需进一步的改进。为了避免随机选取初始聚类中心点的缺陷,张保威^[6]等人通过图像中像素分布的直方图近似确定粗糙度信息,通过得到的粗糙度信息去确定最初的簇中心点。同样为了防止盲目地得到最初的聚类中心,文献[7]利用图像中每个区域中的概率密度峰值点选做最初的中心点,在特定的人脑图像实验结果中,实现了更准确地分割。

Wang^[8]引入了各向异性核函数,并通过MS算法实现了对不同结构的图像进行分割。Chuang^[9]等加入了空间信息函数,同时利用模糊C均值算法使分割后的区域变得更加均匀,同时减少了干扰的噪声点。McClymont^[10]等人通过结合均值漂移算法和图割算法实现了对MRI数据的自动分割,并在两个不同的数据集进行了测试和评估。文献[11]在解决均值算法中的带宽问题时,引入了支持向量机的算法,在均值漂移算法对图像进行预分割之后,再利用支持向量机对其进行分类处理,以此来减少固定带宽带来的影响。

在医学图像的三维重建方面,Christos^[12]等人研发了一个集成系统,该系统可以自动地进行三维重建工作,并且在纵向的研究上可以进行病变区域的检测、提取和跟踪等操作,具有比较大的应用价值。Agostino^[13]等人在利用面绘制处理较大的数据集时,为了防止绘制时间过长,提出一种并行运算的移动立方体(Marching Cube MC)算法,同时引入GPU,也加快了运算的速率。

李泽宇^[14]等人改进了体绘制中的光线投影算法,根据视线和物体距离的关系来调整采样频率的数值大小,由于采样频率的数值影响着模型的细致程度,所以最终提高了成像的质量。张锡英^[15]等人为了减少噪声的影响,在重建之前先利用去噪模型对图像进行了预处理,然后利用MC算法结合心脏数据进行三维重建。文献[16]利用面绘制的方法,同时使用可视化的类库对人体的肺部进行了三维重建,重建结果完整地呈现了人体的肺部组织信息,对肺内部的组织信息也有比较

清晰地呈现。唐振禹^[17]等人在利用 Ray-casting 算法对人体数据进行重建时，不仅在光线的计算方面提前终止，并且引入了 GPU 参与三维数据的绘制，在绘制速度上明显得到了提高，缩短了绘制时间。

此外，在医学三维重建方向上，有些公司已经研发出了成套的系统并应用在了医学领域，例如美国的通用公司 (General Electric) 研制的 (Computed Tomography CT) 设备已具备自动重建的功能，这种螺旋式的 CT 扫描设备内嵌有图形工作站，这种图形工作站可以利用扫描得到的断层数据，直接对其进行三维构建，医生或者研究员可以对其进行实时的交互操作。这种系统需要计算机有十分好的性能，所以价格比较昂贵。对于国内来说，由中科院研发的 3DMed 软件系统，现在已经发布 5.0 版本，在国内处于较领先的地步，对于国内市场，还有很大的发展潜力和推广范围。

1.3 研究目标及主要研究内容

本文的研究目标是基于聚类算法对图像分割进行研究，将分割得到感兴趣区域；然后利用三维绘制算法将分割的目标区域重建为 3 维图像。主要研究内容如下：

(a) 基于模糊C均值的DTI图像分割

FCM算法作为一种“软聚类”，在实现的本质上不同于硬聚类思想，通过给予不同类别不同的权重来划分样本集，在一些聚类效果上更加符合实际的效果。不过，FCM在最初中心点上为随机获取，本文为了消除这种随机性带来的影响，在最初的中心点选择上做出了改变。

(b) 基于均值漂移算法的DTI图像分割

MS算法的过程是在所给数据集中寻找数据点最密集的地方，这个移动是沿着密度不断增加的方向，直到局部密度最大值处。传统均值漂移算法中带宽是人工确定的固定值，其数值大小不仅影响了核函数K的范围，并且影响着最后的漂移结果。当数据点分布均匀时，最终的实验效果不会被带宽所影响。但实际中样本点的分布是不均匀的，人工选取的带宽无法根据像素点分布的情况自动调整，因而无法实现全局最优。本文通过利用调整带宽函数，实现带宽数值的自动改变。

(c) VTK可视化类库的研究

VTK作为一个开源的类库，通过管线的方式完成三维重建。本文通过结合三维可视化的流程对VTK中类库及层次结构进行了研究，通过VTK的可视化管线和渲染管线，并结合Visual Studio 2010 开发平台对绘制算法进行了实现

(d) 通过绘制算法实现分割区域的三维重建

三维绘制算法可以实现将二维断层序列图像信息绘制成三维立体模型，本文

通过对三维绘制算法的研究，结合VTK类库构建绘制流程，将分割得到的信息通过绘制算法实现二维信息转化为三维立体模型。

1.4 本论文的各章节安排

本论文有6个章节，每个章节的安排如下：

第一章说明了本论文的研究背景和意义，列举国内外的研究近况，指明了本文的研究目标和内容，并指出了后续内容的结构安排。

第二章介绍了DTI成像的相关内容，详细推导了张量矩阵的计算方式，并介绍各向异性参数的概念及其计算方式。

第三章首先对图像分割做出了阐述，通过对图像分割算法进行分类，并深入说明了有关区域的两类分割算法，同时结合医学图像的特点，对FCM算法进行改进，完成了对DTI图像的分割。

第四章研究阐述了MS算法，通过研究算法的实现过程，调整了该算法的带宽函数，利用改进的MS算法实现了对DTI图像的分割。

第五章首先阐述了三维重建算法：等值面绘制，并深入研究了该算法的原理，同时阐述了此种算法的应用场景，本章又详细介绍了VTK类库的层次结构及其用法，最后利用VTK结合VS 2010开发平台对数据进行了三维绘制。

第六章对全文内容做了归纳，同时指出了本文的不足，并阐明了以后学术的拓展方向。

第2章 DTI成像原理分析

DTI 作为一种新型成像技术，在弥散加权的基础上发展而来，DTI 能够呈现出其他成像形态所无法显示的信息，在成像的过程无需侵入和造影剂等优点，同时其他成像技术无法比拟的是：只有扩散张量成像技术可以实现活体脑白质微细组织的无创辨识，DTI 成像这种独特的优势在医学领域有很好的应用前景。

2.1 扩散成像

核磁共振^[18]的理论基础是核物理现象。这种现象是由两名研究者 Bloch 和 Purcell 在 1946 年所发现。具体描述如下：在外部磁场影响下，进动的某些原子核，例如氢核，在水分子中没有实现配对，将释放特定频率的电磁波，并用适当的射频电波进行激励，可以使进动角变大，当外部空间的电磁波消失后，原子核将呈现最初的形态，并发出一定的射频信号，该信号与原子核施加的电磁波频率相同，这表现形态就是磁共振现象^[19]。

根据核磁共振现象，核磁共振成像实现过程是患者置身于磁场之中，利用磁场中的脉冲对患者体内的氢原子进行激发，磁场中的脉冲会使体内的氢原子核发生磁共振现象，氢原子核此时也会吸收相应的能量^[20]，当磁场中的脉冲消失时，氢原子核就会通过一定的频率释放出相应的电信号，并会释放在磁场中已经吸收的能量，通过对这些能量信号的收集，最终在显示屏上呈现图像。核磁共振成像以非入侵的特性，在医学影像得到了广泛的发展，同时在医学研究和应用方面发挥着重要的作用。

扩散张量成像作为核磁共振图像的一种，扩散张量成像是将水的布朗运动引入^[21]，通过水的扩散运动来展现组织的内部结构。水在均匀介质和非均匀介质中扩散所呈现的状态也不同，在均匀介质中，水分子在各个方向上扩散的速率是相同的，并且其扩散的强度不会因方向的变化而受到影响，这种特性称之为各向同性。但是在非均匀的介质之中，水分子的扩散呈现出了一定的方向性，原因是在非均匀介质之中存在限制扩散的结构特点，会出现特定方向上扩散系数的数值明显比较高，所以最终的扩散速度是有差别的，这种扩散特性称之为各向异性。脑组织为非均匀的介质，水分子受到了细胞膜和蛋白质分子限制，所以通过水分子的扩散运动可以很好地将不同的脑组织区分开。

2.2 扩散张量

在脑组织中，扩散呈现的是一个三维模态，仅仅利用标量不能完整地呈现所有的信息。此时各向异性的扩散通过一个 3×3 的矩阵来表示，即：

$$D = \begin{bmatrix} D_{xx} & D_{xy} & D_{xz} \\ D_{yx} & D_{yy} & D_{yz} \\ D_{zx} & D_{zy} & D_{zz} \end{bmatrix} \quad (2-1)$$

由于张量矩阵正定对称，这意味着 $D_{xy} = D_{yx}$ ， $D_{xz} = D_{zx}$ ， $D_{yz} = D_{zy}$ ，所以 D 本质上包含有 6 个独立的元素。对于这六个独立的元素，可以通过已加权的图像进行计算，对于加权的图像来说：

$$S(b) = S_0 \exp\left(-\sum_{i,j=x,y,z} b_{ij} D_{ij}\right) \quad (2-2)$$

其中， S_0 表示的是没有经过加权的图像， D_{ij} 表示的是式 (2-1) 中的各个元素， b_{ij} 表示的是 b 因子的元素，其表达式如下：

$$b_{ij} = \gamma^2 G^2 \delta^2 (\Delta - \delta/3) \cdot r_i r_j = b \cdot r_i r_j \quad (2-3)$$

其中， γ 表示的是旋磁比，其数值常常为 $2.675 \times 10^8 \text{ rad/s/T}$ ； G 表示的是脉冲的强度值， δ 表示脉冲的宽度， Δ 表示的是脉冲之间的长度距离。 r_i ， r_j 则分别表示的是单位向量在 i 和 j 两个方向的投影。

对于求解图像中像素点的张量，如果已经知道未加权的图像和加权的图像，则可以对其进行求解，结合公式 (2-2) 和 (2-3) 计算过程如下：

$$\begin{bmatrix} -r_{1x}^2 & -r_{1y}^2 & -r_{1z}^2 & -2r_{1x}r_{1y} & -2r_{1y}r_{1z} & -2r_{1z}r_{1x} \\ -r_{2x}^2 & -r_{2y}^2 & -r_{2z}^2 & -2r_{2x}r_{2y} & -2r_{2y}r_{2z} & -2r_{2z}r_{2x} \\ -r_{3x}^2 & -r_{3y}^2 & -r_{3z}^2 & -2r_{3x}r_{3y} & -2r_{3y}r_{3z} & -2r_{3z}r_{3x} \\ -r_{4x}^2 & -r_{4y}^2 & -r_{4z}^2 & -2r_{4x}r_{4y} & -2r_{4y}r_{4z} & -2r_{4z}r_{4x} \\ -r_{5x}^2 & -r_{5y}^2 & -r_{5z}^2 & -2r_{5x}r_{5y} & -2r_{5y}r_{5z} & -2r_{5z}r_{5x} \\ -r_{6x}^2 & -r_{6y}^2 & -r_{6z}^2 & -2r_{6x}r_{6y} & -2r_{6y}r_{6z} & -2r_{6z}r_{6x} \end{bmatrix} \times \begin{bmatrix} D_{xx} \\ D_{yy} \\ D_{zz} \\ D_{xy} \\ D_{xz} \\ D_{yz} \end{bmatrix} = \begin{bmatrix} \frac{1}{b} \ln \frac{S_0}{S(b_1)} \\ \frac{1}{b} \ln \frac{S_0}{S(b_2)} \\ \frac{1}{b} \ln \frac{S_0}{S(b_3)} \\ \frac{1}{b} \ln \frac{S_0}{S(b_4)} \\ \frac{1}{b} \ln \frac{S_0}{S(b_5)} \\ \frac{1}{b} \ln \frac{S_0}{S(b_6)} \end{bmatrix} \quad (2-4)$$

上式中 $S(b_1)$ 至 $S(b_6)$ 6 幅图像在原始图像的基础上施加了不同脉冲梯度的加权图像，所用的脉冲梯度分别为： $g_1 = [0.707, 0, 0.707]^T T$ ， $g_2 = [-0.707, 0, 0.707]^T T$ ，

$g_3 = [0, 0.707, 0.707]^T T$, $g_4 = [0, -0.707, 0.707]^T T$, $g_5 = [0.707, 0.707, 0]^T T$, $g_6 = [-0.707, 0.707, 0]^T T$, T 表示单位 Tesla。若 b 因子确定时可以分别求出张量各个元素。在实际的求解过程中, 我们也可以采用另外一种方法, 即对偶基底方法, 此方法无需计算张量各个方向的元素值, 可以直接计算得到张量的矩阵 D , 其表达式为:

$$D = \sum_{k=1}^K \frac{1}{b} \ln\left(\frac{S_0}{S_k}\right) G_k^+ \quad (2-5)$$

上式中 G_k 表示的是 g_k 之间的内积, 计算可得:

$$\begin{aligned} G_1 &= \begin{bmatrix} 0.5 & 0 & 0.5 \\ 0 & 0 & 0 \\ 0.5 & 0 & 0.5 \end{bmatrix} & G_2 &= \begin{bmatrix} 0.5 & 0 & -0.5 \\ 0 & 0 & 0 \\ -0.5 & 0 & 0.5 \end{bmatrix} & G_3 &= \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0.5 & 0.5 \\ 0 & 0.5 & 0.5 \end{bmatrix} & G_4 &= \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0.5 & -0.5 \\ 0 & -0.5 & 0.5 \end{bmatrix} \\ G_5 &= \begin{bmatrix} 0.5 & 0.5 & 0 \\ 0.5 & 0.5 & 0 \\ 0 & 0 & 0 \end{bmatrix} & G_6 &= \begin{bmatrix} 0.5 & -0.5 & 0 \\ -0.5 & 0.5 & 0 \\ 0 & 0 & 0 \end{bmatrix} \end{aligned} \quad (2-6)$$

将式(2-6)中的每个矩阵按照列的方式全部排列成列向量的形式, 然后再将所有的列向量组合 9×6 的矩阵, 即矩阵 G :

$$G = \begin{bmatrix} 0.5 & 0.5 & 0 & 0 & 0.5 & 0.5 \\ 0 & 0 & 0 & 0 & 0.5 & -0.5 \\ 0.5 & -0.5 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.5 & -0.5 \\ 0 & 0 & 0.5 & 0.5 & 0.5 & 0.5 \\ 0 & 0 & 0.5 & -0.5 & 0 & 0 \\ 0.5 & -0.5 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.5 & -0.5 & 0 & 0 \\ 0.5 & 0.5 & 0.5 & 0.5 & 0 & 0 \end{bmatrix} \quad (2-7)$$

G^+ 表示的是矩阵 G 的伪逆矩阵, 所以可以得到矩阵 G^+ 为:

$$G^+ = \begin{bmatrix} 0.5 & 0 & 0.5 & 0 & -0.5 & 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & -0.5 & 0 & -0.5 & 0 & -0.5 & 0 & 0.5 \\ -0.5 & 0 & 0 & 0 & 0.5 & 0.5 & 0 & 0.5 & 0.5 \\ -0.5 & 0 & 0 & 0 & 0.5 & -0.5 & 0 & -0.5 & 0.5 \\ 0.5 & 0.5 & 0 & 0.5 & 0.5 & 0 & 0 & 0 & -0.5 \\ 0.5 & -0.5 & 0 & -0.5 & 0.5 & 0 & 0 & 0 & -0.5 \end{bmatrix} \quad (2-8)$$

通过式 (2-8) 就可以得到 6 个矩阵, 每个矩阵大小为 3×3 。即;

$$\begin{aligned}
G_1^+ &= \begin{bmatrix} 0.5 & 0 & 0.5 \\ 0 & -0.5 & 0 \\ 0.5 & 0 & 0.5 \end{bmatrix} & G_4^+ &= \begin{bmatrix} -0.5 & 0 & 0 \\ 0 & 0.5 & -0.5 \\ 0 & -0.5 & 0.5 \end{bmatrix} & G_2^+ &= \begin{bmatrix} 0.5 & 0 & 0.5 \\ 0 & -0.5 & 0 \\ -0.5 & 0 & 0.5 \end{bmatrix} \\
G_3^+ &= \begin{bmatrix} -0.5 & 0 & 0 \\ 0 & 0.5 & 0.5 \\ 0 & 0.5 & 0.5 \end{bmatrix} & G_5^+ &= \begin{bmatrix} 0.5 & 0.5 & 0 \\ 0.5 & 0.5 & 0 \\ 0 & 0 & -0.5 \end{bmatrix} & G_6^+ &= \begin{bmatrix} 0.5 & -0.5 & 0 \\ -0.5 & 0.5 & 0 \\ 0 & 0 & -0.5 \end{bmatrix} \quad (2-9)
\end{aligned}$$

最后把(2-5)中的参数换为(2-9)就可以计算出张量矩阵D。

其中张量矩阵D通过对角化可以得到确定张量形状的三个正特征值($\lambda_1 > \lambda_2 > \lambda_3$)和确定特征值方向的3个正交特征向量($\vec{e}_1, \vec{e}_2, \vec{e}_3$), 转换过程如式(2-10)所示:

$$D = \begin{bmatrix} D_{xx} & D_{xy} & D_{xz} \\ D_{yx} & D_{yy} & D_{yz} \\ D_{zx} & D_{zy} & D_{zz} \end{bmatrix} = \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix} \cdot \begin{bmatrix} \vec{e}_1 \\ \vec{e}_2 \\ \vec{e}_3 \end{bmatrix} \quad (2-10)$$

$\sqrt{\lambda_1}, \sqrt{\lambda_2}, \sqrt{\lambda_3}$ 分别代表了最长的轴, 第二长轴和最短轴的长度 $\vec{e}_1, \vec{e}_2, \vec{e}_3$ 特征值方向分别代表了 $\sqrt{\lambda_1}, \sqrt{\lambda_2}, \sqrt{\lambda_3}$ 三个主轴线的方向(如图2-1)。




图 2-1 张量扩散形状

通过张量得出的三个特征值 λ 数值之间的关系决定了椭球的外形, 因此, 三个 λ 数值之间的不同关系会呈现不同的扩散类型。

线性扩散: $\lambda_1 \geq \lambda_2 \geq \lambda_3$, 这种扩散形态出现在脑白质组织内, 此时扩散的类型呈现为扁圆形(如图2-2(a))。

平面扩散: $\lambda_1 \approx \lambda_2 \geq \lambda_3$, 这种扩散常常表现在神经纤维交叉的地方, 并在交叉处呈现出圆盘的形状(如图2-2(b))。

各向同性扩散: $\lambda_1 \approx \lambda_2 \approx \lambda_3$, 比如脑组织中的灰质扩散形式, 该形态呈现的是球形(如图2-2(c))。




图 2-2 三种不同的扩散方式

2.3 各向异性参数的测度

相比于普通的 MR 图像, 各向异性参数从不同的角度体现了张量的特性, 计算得到的扩散张量各向异性参数可以呈现出独一无二的组织结构信息, 主要的各向异性参数^[22]有:

a. 扩散张量的迹 (Trace) $Tr(D)$

迹 ($Tr(D)$) 是其三个特征值 ($\lambda_1, \lambda_2, \lambda_3$) 的和, 由于水分子脑组织内的扩散为椭球体, 迹的数值体现了是椭球体的大小, 其扩散的程度与方向无关, 具体表达式为:

$$Tr(D) = D_{xx} + D_{yy} + D_{zz} = \lambda_1 + \lambda_2 + \lambda_3 \quad (2-11)$$

b. 部分各向异性 (Fractional Anisotropy FA)

FA 是通过两种成分的比值得到, 分子为张量各向异性成分, 分母为 λ 的平方加和形式^[23]。

$$FA = \sqrt{\frac{3 * \left[\left(\lambda_1 - \bar{\lambda} \right)^2 + \left(\lambda_2 - \bar{\lambda} \right)^2 + \left(\lambda_3 - \bar{\lambda} \right)^2 \right]}{2 * (\lambda_1^2 + \lambda_2^2 + \lambda_3^2)}} \quad (2-12)$$

$$\bar{\lambda} = (\lambda_1 + \lambda_2 + \lambda_3) / 3 \quad (2-13)$$

c. 线性因数 (CL)

$$CL = \frac{(\lambda_1 - \lambda_2)}{3 * \bar{\lambda}} \quad (2-14)$$

d. 平面因数 (CP)

$$CP = \frac{2 * (\lambda_2 - \lambda_3)}{3 * \bar{\lambda}} \quad (2-15)$$

e. 球形因数 (CS)

$$CS = \frac{\lambda_3}{\bar{\lambda}} \quad (2-16)$$

其中 $CL + CP + CS = 1$ ，若 CL 的值在扩散区域比较高，那么该区域呈现的则是线性扩散；如果 CP 的数值较大，则呈现的是平面扩散；如果 CS 的数值近似等于 1，那么呈现的形状是球形，即为各向同性扩散^{[24][25]}。并且不同的扩散形态分布于三角形的各个顶点区域，如下图所示：




图 2-3 扩散张量的重心空间

f. 相对各向异性 RA (Relative anisotropy)

$$RA = \frac{1}{\sqrt{3}} \frac{\sqrt{\sum_{i=1,2,3} (\lambda_i - \bar{\lambda})^2}}{\bar{\lambda}} \quad (2-17)$$

此外，通过 λ ，我们还可以得到其他类型的参数：

$$A_{ratio} = \lambda_1 / \lambda_3 \quad (2-18)$$

$$A_{ratio, m_2} = \frac{\lambda_1}{(\lambda_2 + \lambda_3) / 2} \quad (2-19)$$

$$A_{major} = \frac{2\lambda_1 - \lambda_2 - \lambda_3}{3\bar{\lambda}} \quad (2-20)$$

$$A_\sigma = \frac{1}{\sqrt{6\bar{\lambda}}} \sqrt{\sum_{i=x,y,z} (D_{ii} - \bar{\lambda}) + 2(D_{xy}^2 + D_{xz}^2 + D_{yz}^2)} \quad (2-21)$$

2.4 本章小结

本章首先通过引入核物理上的磁共振介绍核磁共振成像的原理，然后通过水

分子在不同介质中的运动介绍扩散的各向同性和各向异性,之后介绍扩散张量基本概念,在介绍扩散张量的同时详细推导了扩散张量矩阵 \mathbf{D} 的计算过程,并通过扩散张量矩阵计算出三个特征值 $\lambda_1, \lambda_2, \lambda_3$ 数值,通过三个特征值数值的大小关系可以得到水分子三种不同的扩散表征:线性扩散,平面扩散和各向同性扩散。此外,在我们得到特征值 λ 数值时,计算出了扩散的各向异性参数,同时表明了每个各向异性参数的含义。

第3章 图像分割与模糊C均值算法

3.1 图像分割概述

图像分割^[26]就是按照某种属性将图像划分为两个甚至多个区域，相同区域中的数据属性相同，不同区域中的数据属性不同。我们通过集合来对图像分割进行说明，规定集合 R 表示待分割的整个数据集，图像分割就是将数据集 R 分为 L 个子集 $R_1, R_2, R_3, \dots, R_L$ ，此时 L 个子集有如下约束条件：

1. $\bigcup_{i=1}^L R_i = R$;
2. 对于的任何两个子集都有， $R_i \cap R_j = \phi$;
3. 对于 $i=1, 2, 3, \dots, L$ ，满足 $G(R_i) = TRUE$;
4. 对于两个不同的子集 R_i 和 R_j ，满足 $G(R_i \cup R_j) = FALSE$;
5. 其中对于任何一个子集 R_i 而言，该子集是一个连通集。

其中， $G(R_i)$ 表示的是划分集合的逻辑属性， ϕ 表示的是空集， \cup 和 \cap 分别表示的是集合的并和交。条件 1 表明的是分割必须是完全的状态，即分割结果中全部子集像素点数量的总和等于原始图像全部的像素点个数。条件 2 指出每个子集是不相交的，即两个不同的子集不能包含同一个像素点。第 3 条表明的是每个子集中像素点所体现的属性，即同一个子集中全部像素点具有一致的属性，如果集合 R_i 中的数据点都有一致的灰度级，则 $G(R_i) = TRUE$ 。条件 4 表明两个不同的子集在逻辑属性上的意义必须是不同的，两个区域没有共同的属性。条件 5 表明的是同一个子集中满足连通的性质，比如满足 4 连通或者 8 连通。

图像分割在遵循上述条件的情况下，将整个数据集分割成不同的区域。其中，对于不同分布特性的图像不能采用相同的方法，因为仅仅一种单一的算法无法适用于所有的图像。有些分割算法在某种特定的图像中表现较佳，但是在另外一种类型的图像中分割效果较差。针对这种问题，研究者采用不同类型的算法，按照非细致的划分，可以将其划分为按照区域和边界的分割算法^[27]。对于按照区域的划分标准中，通过区域的相似性进行划分，即利用同一区域中具有相似特性的规则划分，比如纹理，灰度等。而对于边界的区分方法中则是利用了不同区域的非连续特性实现区分。对于按照区域划分的标准中，比较常用是阈值法和区域生长法。作为阈值分割法，该种算法实现的是将感兴趣区域和背景利用灰度上差异形成不同的组合，对一幅图像中这两类组合在灰度值差异比较大情况下，此时阈值分割法会实现有效的分割^[28]。对于区域生长法^[29]来说，通过将具有一定数量的像

素组合起来形成一个区域，该区域中的每个像素都具有相似性的特点。算法过程是先设置一个种子像素点，其作用是使其作为生长的起点，其中种子是按照某种事先规定的原则进行生长，在种子的生长过程中将判断种子像素点周围的像素点，如果某个数据点和种子像素点符合预先设定的准则，则将该数据点合并到种子点所生长的范围，直到没有满足的像素点为止，此时则形成了像素区域集合。当然，还有通过聚类对图像实现分割，利用边缘检测等各种算法，下面将会对几种图像分割算法进行分析和研究。

3.2 区域分割算法

3.2.1 阈值分割算法

阈值分割算法^[30]作为区域分割算法的一种，在实现原理上比较简单，该算法在图像分割时将图像分为不同灰度级的区域，通过设置一个阈值，并将所有数据点与阈值进行比较，根据两者数值之间大小关系将该数据点划分在不同的区域，且最终的分割结果是二值图像。其中 $h(x, y)$ 是待处理的图像，其中阈值设置为 T ，最后的结果图像是 $g(x, y)$ ，则有以下式：

$$g(x, y) = \begin{cases} 1 & h(x, y) \geq T \\ 0 & h(x, y) < T \end{cases} \quad (3-1)$$

或者

$$g(x, y) = \begin{cases} 1 & h(x, y) \leq T \\ 0 & h(x, y) > T \end{cases} \quad (3-2)$$

如果想要实现最后的图像在一个灰度区间范围为 1，其余像素值为 0，则可定义：

$$g(x, y) = \begin{cases} 1 & T_1 \leq h(x, y) \leq T_2 \\ 0 & \text{其他} \end{cases} \quad (3-3)$$

由此我们可以得出阈值分割法一般表示形式：

$$g(x, y) = \begin{cases} R_E & h(x, y) \in R \\ R_B & \text{其他} \end{cases} \quad (3-4)$$

此处 R 作为一个灰度值范围的集合，对于阈值法而言，阈值的正确选择是该算法的关键，当阈值的取值过大时，会错将感兴趣区域中样本点分类到背景区域，当阈值设置的过低时，两类区域中的数据点同样会出现错误分类。当待分割的图像中有比较复杂的变化时，比如光线的不均匀，阴影等，同时感兴趣区域和背景

两部分的灰度变化不明显时，如果此时利用单一的阈值去分割整幅图像时，最终的分割效果会比较差。因此下面将引入两种改进的算法：最大方差阈值分割^[31]和自适应阈值分割。

1) 最大方差阈值分割

对于待分割的图像而言，假设图像中总共有 N 个像素点，其中像素值的范围是 $[0, L-1]$ ，对于像素值为 i 的个数为 n_i ，此时我们可以得到概率：

$$p_i = \frac{n_i}{N} \quad (3-5)$$

我们可以利用阈值 T 将图像分为两类，对于灰度值范围在 $[0, T-1]$ 的像素点为 A_0 ，则灰度值在范围 $[T-1, L-1]$ 为 A_1 ，对于这两类其概率分别为：

$$A_0 = \sum_{i=0}^{T-1} p_i \quad (3-6)$$

$$A_1 = \sum_{i=T}^{L-1} p_i = 1 - A_0 \quad (3-7)$$

其中 A_0 和 A_1 两者的均值分别为：

$$K_0 = \sum_{i=0}^{T-1} ip_i / A_0 \quad (3-8)$$

$$K_1 = \sum_{i=T}^{L-1} ip_i / A_1 \quad (3-9)$$

则可以得到待分割图像的均值：

$$K = A_0 K_0 + A_1 K_1 \quad (3-10)$$

此时我们可以定义类间方差：

$$\sigma^2 = A_0(K_0 - K)^2 + A_1(K_1 - K)^2 = A_0 A_1 (K_0 - K_1)^2 \quad (3-11)$$

令 T 以步长为 1 在范围 $[0, L-1]$ 内增长时，直到 σ^2 取值最大时对应的阈值 T 则为所求阈值。

2) 自适应阈值分割

对于自适应阈值分割^[32]，该算法在阈值选取上的基本思想为：首先对图像中每个像素点做遍历处理，并以每个像素点为中心确定一个连通区域，寻找该连通区域的最大灰度值和最小灰度值，然后将两者的算术平均值作为该连通区域的阈值。如图 3-1 所示，以点 Q 为中心确定了生长区域(八连通)，其中，该连通区域中像素值最大为 max_value ，最小为 min_value ，则我们可以得到阈值为：

$$T = \frac{\max_value + \min_value}{2} \quad (3-12)$$

P_1	P_2	P_3
P_4	Q	P_5
P_6	P_7	P_8

图 3-1 阈值分割连通区域

其中, p_i 为 Q 的八连通像素点。当连通区域的像素点越多时, 计算量就会相应的提升, 在实际应用中, 一般选择八连通区域。

3.2.2 区域生长与分裂合并

(1) 区域生长

区域生长算法也即种子区域增长算法(seeded region growing)^[33]在被提出之后经过多年的发展成为了一种比较实用的分割算法。算法的基本思想是设置生长的起始点, 起始点的设置可以是一个或者多个, 其生长的规则是人为指定, 根据生长的规则将把与种子点相似的样本点归并到种子点的区域之中, 同时将归并的数据点作为新的生长点, 搜索所有的数据点, 直到没有新的数据点再合并到生长的区域为止。

对于单种子点来说, 首先指定种子点, 比较周围邻域(4 连通或者 8 连通)与种子点之间的相似性, 相似性一般选择灰度值的绝对值差, 对符合特性的像素点进行合并, 将新合并的像素点作为新的中心点继续相同的操作, 直至全部合并完成。下面以矩阵说明种子点的生长过程:

0	11	8	7
7	6	5	6
2	3	1	2
8	0	9	10

0	11	8	7
7	6	5	6
2	3	1	2
8	0	9	10

0	11	8	7
7	6	5	6
2	3	1	2
8	0	9	10

(a) 初始种子点

(b) 生长过程图

(c) 生长结果图

图 3-2 种子生长过程图

图 3-2 (a)中是一个像素矩阵, 其中我们将 6 作为种子点, 此处生长的范围大小为 4 邻域区域, 阈值大小设置为 2, 当 4 邻域中的像素点与种子点的阈值差小于 2 时, 将该数据点作为新的生长点。图(b)作为第一次生长过程, 可以看到像素

点 5, 7 与种子点 6 的绝对值之差小于 2, 所以对其进行归并操作, 而 3 和 8 不满足阈值条件, 则不做处理。将 5 和 7 当作新的种子像素点并遵循规则进行生长, 并同样将新加入的样本点作为新的种子点进行生长, 经过生长过程最终的生长结果如图 3-2(c)所示。

(2) 区域分裂合并法

种子增长法适用于种子像素点周围有连续相似的像素点, 但当种子像素点与周围的像素点差异较大时, 此时区域增长不再适用, 此时通过区域分裂合并法对其进行操作^[34]。种子增长法是从一个像素点出发逐渐扩大区域直到该区域没有新的像素点加入, 区域分裂合并法更像其逆过程, 该算法是从整个图像出发, 把其分为各个小区域, 再把相似的区域进行合并。

该算法的实现过程是首先明确一个准则(一般为一致性), 其规则决定区域的变化过程, 如果当前区域不符合该条件时, 则就将该区域进行分裂为多个相等的子集, 然后遍历全部子区域, 将符合当前条件的子区域做归并处理。

在进行分裂过程中, 一般采用四叉树的数据结构形式对其进行划分, 根节点作为整个数据集, 在实现划分的过程中将区域分为 4 个无差异的子区域。图 3-3 (a)和(b) 呈现了区域分裂和四叉树结构关系。

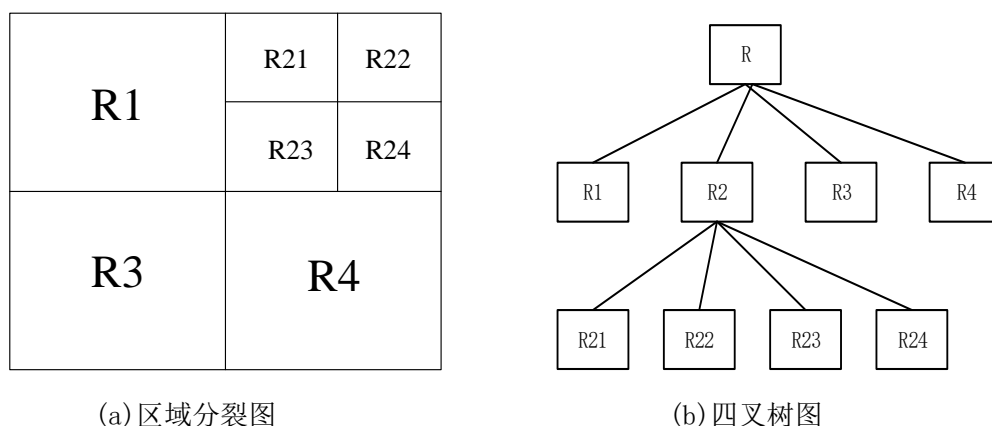


图 3-3 区域分裂与四叉树结构图

在进行区域的分裂之前需要首先定义具有相同性质的谓词 H , 令 R 表示整幅图像, R_i 表示一个子区域, 对于任何一个子区域 R_i 来说, 当 $H(R_i) = TRUE$ 时, 说明此区域中的像素点具有相同的性质, 如果 $H(R_i) = FALSE$ 时, 则需将该区域分为 4 个子区域。当图像中所有的子区域满足 $H(R_i) = TRUE$ 时则停止分裂。

当把图像分裂成有一致属性的子图像时, 接下来需要利用区域合并方法将相邻且具有一致属性的子区域进行合并。对于合并要确定的是子区域之间相似性, 两个子区域之间相似性的判断可以比较两者之间的灰度均值, 当两者之间的像素

均值小于预先设置的阈值，则可以对其进行归并操作。另外，区域合并判断的条件可以采用与区域分裂一致的规则。

3.3 模糊C均值算法

对于医学图像的分割^[35]来说，分割目的是实现不同组织之间的分离，对分割后的组织可以辅助医生进行诊断或者三维重建等后续操作，是后续各项操作的准备工作。但是医学图像不同于一般的图像，相对于一般自然的图像，医学图像存在部分容积效应和强度不一致的特性。部分容积效应是由于成像设备所导致的，具体是指对同一层的某个数据信息进行采集的时候，如果在该层中包含了两种以上的数据信息时，则采集到的数据信息是这些信号的平均值，而不是单个数据信息。在医学图像中，部分容积效应表现为：一个数据点的值是连通区域内所有数据点灰度的均值，不能真正反映该数据点的灰度值，甚至还会导致图像中强度不一致，强度不一致的具体表现为对于同一组织内的像素分布，组织边缘的灰度值和中心的像素值不同。模糊C均值作为一种“软聚类”技术，在聚类的时候可以不仅仅考虑像素属于某一特定区域，通过综合利用像素的信息，对数据进行聚类分析。

FCM 算法^[36]作为一种常用的非监督聚类算法，在模式分类、图像分割等方面有了较多地使用。相比于硬C算法，FCM 在分割的过程中会保留关于所需区域的更多信息，这对医学图像来讲尤为重要，模糊C均值算法的基本思想是通过数据点和聚类中心点相似性最低化实现数据的划分，主要是对两个函数不断地更新，分别隶属度函数和聚类中心点函数，从而使目标函数的数值达到最小^{[37][38]}。模糊C均值目标函数定义式为：

$$J_z(M, N) = \sum_{l=1}^S \sum_{k=1}^R (m_{kl})^z \|x_l - n_k\|^2 \quad (3-13)$$

其中， M 为隶属度的集合， N 是迭代更新的中心点的集合，模糊加权指数此处用 z ，缺省值是 2， $N = \{n_1, n_2, \dots, n_R\}$ ， N 是聚类中心点集合， m_{kl} 为某个样本点是某一类的隶属度函数， $\|x_l, n_k\|^2$ 的含义是第 l 个数据点到第 k 类中心点的聚类距离，度量方法为欧几里得度量。通过对式(3-13)目标函数求极值，利用拉格朗日乘法，由于某一个样本到所有类的隶属度之和为 1，可以得出

$1 - \sum_{k=1}^R m_{kl} = 0$ ，然后将该等式再回代到式(3-13)可得：

$$J_z(M, N) = \lambda(1 - \sum_{k=1}^R m_{kl}) + \sum_{l=1}^S \sum_{k=1}^R (m_{kl})^z \|x_l - n_k\|^2 \quad (3-14)$$

对(3-14)式中的 λ ，隶属度和中心点函数求偏导可得：

$$\frac{\partial J}{\partial \lambda} = 1 - \sum_{k=1}^R m_{kl} \quad (3-15)$$

$$\frac{\partial J}{\partial m_{kl}} = -\lambda + z m_{kl}^{z-1} \|x_l - n_k\|^2 \quad (3-16)$$

$$\frac{\partial J}{\partial n_k} = 2 \sum_{l=1}^S (m_{kl})^z (n_k - x_l) \quad (3-17)$$

现在令上述三个偏导方程等于0，由式(3-16)可得：

$$m_{kl} = \left(\frac{\lambda \times \frac{1}{z}}{\|x_l - n_k\|^2} \right)^{-(z-1)} \quad (3-18)$$

由式(3-17)可得：

$$n_k = \frac{\sum_{l=1}^S m_{kl}^z \times x_l}{\sum_{l=1}^S m_{kl}^z} \quad (3-19)$$

其中， n_k 为迭代求出的聚类中心点函数。

将式(3-18)代入式(3-15)可得：

$$1 - \sum_{k=1}^R \left(\frac{\lambda \times \frac{1}{z}}{\|x_l - n_k\|^2} \right)^{-(z-1)} = 0 \quad (3-20)$$

将式(3-20)化简可得：

$$\left(\lambda \times \frac{1}{z}\right)^{-(z-1)} = \frac{1}{\sum_{k=1}^R \frac{1}{\|x_l - n_k\|^{-2(z-1)}}} \quad (3-21)$$

进而将式(3-21)代入式(3-18)可得：

$$m_{kl} = \frac{1}{\sum_{j=1}^R \left(\frac{\|x_l - n_k\|}{\|x_l - n_j\|} \right)^{-2(z-1)}} \quad (3-22)$$

所以最终可得隶属度函数为(3-22)式中 m_{kl} 所示。

3.4 改进的模糊 C 均值算法

传统的模糊 C 均值在最初心点的选取上存在缺点，其选取的方法存在随机性，由于最终的收敛结果依赖于初始中心点的位置，当选取的初始中心点和最终的收敛结果比较接近时，收敛不会受到初始中心点的作用，但是当初始的中心点接近于某个数据区域的极值时，最终结果就出现局部收敛，因而无法实现全局最优。

对于收敛结果对最初的中心点敏感的情况，本章节采用采用最大最小距离^[39]的方法来确定初始聚类中心点，具体步骤为：

1. 对于数据集中的 m 个数据点， l_m 是所有数据点的集合记为 $l_m = \{x_1, x_2, x_3, \dots, x_m\}$ ，从 m 个数据点中选出一个当作第一类中心点，并记为 $P\{1\}$ 。
2. 求出剩余数据点到第 $P\{1\}$ 的欧式距离，令距离最大值对应的数据点作为第二类聚类中心点，并记做 $P\{2\}$ 。
3. 对数据集 l_m 中剩余的所有数据点 x_i ，分别求出到聚类中心点 $P\{1\}$ 和 $P\{2\}$ 的欧式距离 d_{i1} 、 d_{i2} ，将 d_{i1} 与 d_{i2} 中的最小值放入集合 D 中记为 $D = \{\min(d_{i1}, d_{i2})\}$ ，在集合 D 求出最大值对应的 x_i 选作第三类中心点，记为 $P\{3\}$ 。

3.5 DTI 图像分割步骤及流程

利用最大最小值确定的最初中心点可以避免随机选取初始中心点的缺陷，FCM 通过确定的中心点对 DTI 图像处理的具体步骤为：

1. 读入待分割的 DTI 图像，并计算相应的各向异性参数；
2. 利用 3.4 小节算法确定数据集中的最初中心点，并设定阈值 ε ；
3. 通过数据集和聚类中心点确定式(3-22)中的的隶属度函数 m_{kl}^r ， r 代表迭代次数；
4. 通过数据集和更新的隶属度函数计算更新式(3-19)中的中心点函数 n_k^r ， r 含义是计算的次数；
5. 不断地迭代更新步骤 3 和步骤 4 中的隶属度函数和聚类中心点函数，直到 $\|n_k^{r+1} - n_k^r\| < \varepsilon$ ，输出最终的结果。

同时，DTI 图像分割的算法流程如下：

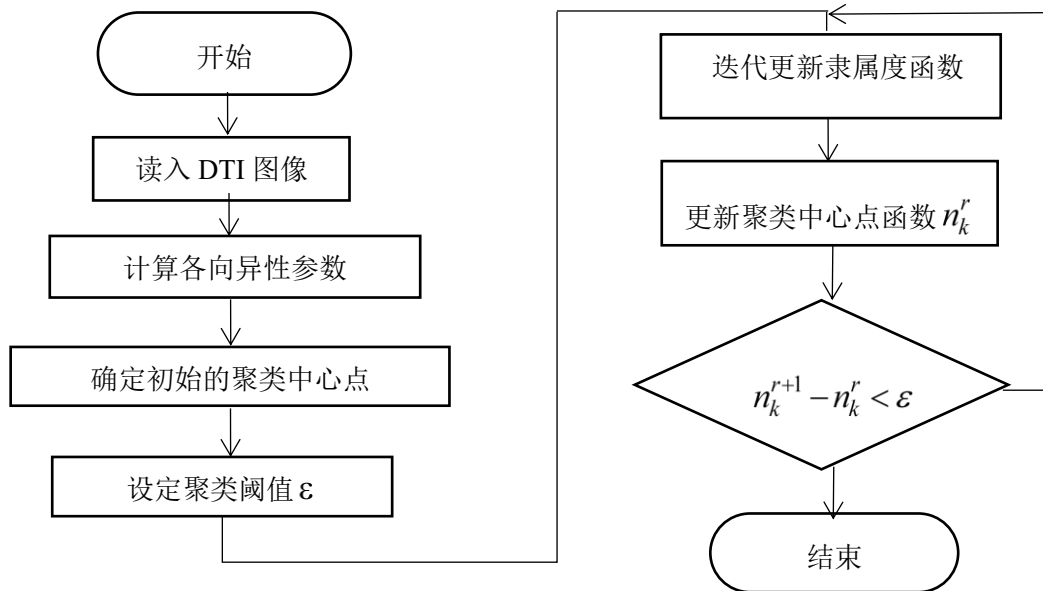


图 3-4 算法流程图

3.6 实验结果及讨论

本文所使用数据是由明尼苏达大学提供。7 幅 DTI 图像所加梯度脉冲的方向分别为：(0 0 0)、(0.707 0 0.707)、(-0.707 0 0.707)、(0 0.707 0.707)、(0 0.707 -0.707)、(0.707 0.707 0)、(-0.707 0.707 0)，轴向为 58 层，体元大小为 $2\text{mm} \times 2\text{mm} \times 2\text{mm}$ ， $\text{TE}=95\text{ms}$ ， $\text{TR}=8.7\text{s}$ 。

该实验所用的数据为第 26 层、30 层、33 层以及 DTI 图像的各向异性参数进行分割，用来验证改进后算法的准确性。所有的实验均是基于 Matlab R2012a 编

程环境,在 Windows 7 操作系统,2.10 GHZ 的 CPU,4G 内存的 Intel(R) Core(TM)i3 的 Lenovo 笔记本电脑上仿真实现。

如图所示,图 3-5(a)、(b)和 (c)分别为第 26 层人脑图像、第 26 层算法改进前实验结果和算法改进后的实验结果。图 3-4(d)、(e)和 (f)分别为第 30 层人脑图像、第 30 层算法改进前实验结果和算法改进后的实验结果。图 3-4(g)、(h)和 (i)分别为第 33 层人脑图像、第 33 层算法改进前实验结果和算法改进后的实验结果。




图 3.5 算法改进前后分割结果对比图

从人脑 DTI 图像分割实验结果对比可以发现,使用改进前的 FCM 算法分割得到的胼胝体边缘轮廓粗糙,并且周围有较多错误分割的区域,说明传统的 FCM 聚类算法分割的准确性不高。基于本文改进 FCM 聚类算法对胼胝体进行分割,分割得到的胼胝体边缘光滑清晰,并且周围错误分割的区域很少,说明改进后的分割算法准确性得到了提高。

图 3-6(a)、(b)和 (c)依次是 FA 图像、算法改进前的实验结果和算法改进后的实验结果。图 3-6(d)、(e)和 (f)依次为 MD 图像、算法改进前的实验结果和算

法改进后的实验结果。




图 3-6 算法改进前后 FA 和 MD 图像的分割结果

从 DTI 图像各向异性参数的实验结果对比使用该改进前的 FCM 聚类分割 FA 和 MD 图像的胼胝体, 会出现许多的错误区域, 分割得到的胼胝体边缘信息不清晰, 说明分割的准确性低且效果比较差。每次分割还存在随机散落分布的异常点, 说明分割的稳定性比较差。而采用本文的分割算法, 分割效果得到了明显改善, 胼胝体的边缘光滑清晰, 避免了随机选取初始聚类中心点导致结果中较多异常点的缺点, 实验结果的准确性实现了提高。

由以上实验结果可知, 利用确定的最初中心点去进行分割实验, 相比于传统的 FCM 算法随机确定初始中心点进行实验, 能够得到更清晰的边缘纹理, 分割结果的准确率更高, 并且能够消除分割结果中随机的异常点, 稳定性得到了提高。

3-7 本章小结

此章先对图像分割做了概述, 又详细阐述了基于区域的两种分割算法: 阈值分割算法和区域生长与分裂合并算法, 同时结合图像分割的特性引入了 FCM 算法。通过介绍 FCM 算法的原理, 针对传统的 FCM 算法产生最初中心的方式, 分割结果中有很多的异常点且边缘信息比较模糊, 分割准确率低的缺点, 本章节通过选取确定的初始聚类中心点, 在避免结果陷入局部极小值的同时, 提高了分

割的准确性，保证了分割结果的稳定性，分割的效果得到了明显的改善。

根据本章节改进的FCM算法对人脑第26层、30层和33层以及各向异性参数FA和MD图像进行了分割实验.从实验结果对比来看，本文分割算法结果显示胼胝体的边缘轮廓信息清晰且异常点明显减少，在提高分割准确性的同时，很大程度上也改善了分割的效果。

第4章 基于带宽的均值漂移算法

均值漂移算法作为一种区域性的分割算法，最初在 1975 年由 Fukunaga 等人发表论文提出，该论文主要是围绕密度函数估计在模式识别中的应用展开论述，并在文章中提出了均值漂移的概念，当时的概念是指偏移的均值向量。其后多年，均值漂移一直没有得到发展，直到后来，由 Cheng^[40]推动了该算法的发展，其主要在两个方面做出了改进：第一通过给予不同的数据点不同的权重，使不同的数据点在进行迭代运算时体现不同的权重比例；第二通过引入核函数，利用数据点和中心点的距离不同进而判断此偏移量在最终偏移量中的影响权重。之后，由 Comaniciu^{[41][42]}等人在带宽密度估计的基础上提出，通过寻找局部密度的极值，达到收敛的效果，并成功应用到了图像分割和目标跟踪的领域，进一步推动了该算法的发展和扩大了应用的领域。

均值漂移算法在进行数据聚类时不用指明最初的聚类中心点，并且具有鲁棒性强的优点。在对 DTI 图像进行分割的过程中，本章使用的是一种自适应的均值漂移算法，通过改进带宽函数，实现 DTI 图像的分割。

4.1 均值漂移算法

4.1.1 初始均值漂移算法

最初的均值漂移算法由 Fukunaga^{[43][44]}1975 年在发表的论文中指出，算法基本思想为：已知在样本空间中存在一 n 个样本点组成的集合 $\{x_i | 1 \leq i \leq n\}$ ，其均值漂移向量^[45]定义为：

$$M_r(x) = \frac{1}{n} \sum_{x_i \in C_r} (x_i - x) \quad (4-1)$$

其中， n 表示处于半径为 r 的 C 圆内样本点的数目， $(x_i - x)$ 表示数据点 x_i 相对于当前圆心 x 的相似度量，即偏移量；式 (4-1) 表示圆内区域所有数据点相对于中心点 x 偏移量总和的平均值。

均值漂移算法的基本思路是搜索所给数据集中数据点最密集的区域，沿着密度增大的方向漂移到密度最大值处（如图 4-1 所示）。不同于其他聚类算法，漂移寻找局部最大值是不断迭代的过程，所以不需要先验知识。最终的聚类结果不依赖于初始条件，这种特性对样本点的聚类能产生很好的效果，并且对任意形状

的样本点分布都有效。均值漂移算法核心思想是对数据集中的样本点进行聚类，利用梯度上升法去搜寻概率密度梯度的峰值。



图 4-1 均值漂移算法

4.1.2 扩展的均值漂移算法

由于初始的均值偏移向量在计算时没有考虑距离因素，将和基准点距离不同的数据点赋予相同的权重因子，实际上和基准点 x 距离不同的数据点 x_i 产生的偏移量对评估总的偏移量统计特性的影响是不同的，为了解决这一问题所以引入了核函数。


核函数^[41]的定义：令 X 为一个 n 维的欧氏空间，由 i 各样本点组成 $x_i \in X$ ，并且 x 为非负值，满足 $\|x\|^2 = \sum_{i=1}^n |x_i|^2$ 。对于函数 $K: K(x) = k(\|x\|^2)$ ，其中 $X \rightarrow R$ ， $k: [0, \infty] \rightarrow R$ ，当满足下列三个条件时， $K(x)$ 可以成为核函数^{[44][46]}：

- k 为非负数
- k 为非增函数，即 $a > b$ ， $k(a) \leq k(b)$
- k 为分段连续函数并且 $\int_0^{\infty} k(r) dr < \infty$


应用比较广泛的两种的核函数分别为：

单位高斯核函数^{[47][48]}：
$$G(x) = e^{-\|x\|^2} \quad (4-2)$$

单位均匀核函数：
$$F(x) = \begin{cases} 0 & \|x\| > 1 \\ 1 & \|x\| \leq 1 \end{cases} \quad (4-3)$$



(a) 单位高斯核函数



(b) 单位均匀核函数

图 4-2 两种不同核函数

另外由于对于单个数据点来说,每个数据点对迭代运算贡献大小也是不同的,所以对单个数据点引入权重因子,将每个数据点的权重表示出来。综合核函数和权重因子,均值偏移向量扩展形式是:

$$M(x) = \frac{\sum_{x_i \in X} K_H(x_i - x)w(x_i)(x_i - x)}{\sum_{x_i \in X} K_H(x_i - x)w(x_i)} \quad (4-4)$$

其中, $w(x_i)$ 为数据点 x_i 的权重数值, 并满足 $\sum_{x_i \in X} w(x_i) = 1$; $K(x)$ 为核函数,

$K(x_i - x) = |H|^{-1/2} K(H^{-1/2}(x_i - x))$; 对于带宽矩阵 $H = hI$, h 表示漂移带宽, I 表示单位矩阵, 上式(4-4)经化简常表示为:

$$M_h(x) = \frac{\sum_{x_i \in X} K\left(\frac{x_i - x}{h}\right)w(x_i)x_i}{\sum_{x_i \in X} K\left(\frac{x_i - x}{h}\right)w(x_i)} - x \quad (4-5)$$

可进一步表示为 $M_h(x) = m_h(x) - x$, 其中样本均值 $m_h(x)$ 即为:

$$m_h(x) = \frac{\sum_{x_i \in I}^n K\left(\frac{x_i - x}{h}\right)w(x_i)x_i}{\sum_{x_i \in I}^n K\left(\frac{x_i - x}{h}\right)w(x_i)} \quad (4-6)$$

通过核函数和权重函数重新定义了均值漂移向量的形式, 进一步该算法的计算过程如下:

- 1) 通过式(4-6)计算出样本均值函数 $m_h(x)$;
- 2) 得出数据点的均值 $m_h(x)$ 和基准点 x 之间偏移值;

通过给定一个比较小的误差值 ε , 通过比较偏移量的大小来判断是否继续迭代运算, 当 $\|m_h(x) - x\| > \varepsilon$ 时, 此时将样本均值 $m_h(x)$ 的值赋给基准点, 继续执行算法的步骤 1 和 2; 如果 $\|m_h(x) - x\| \leq \varepsilon$, 说明此时算法已经收敛, 算法结束。

4.2 改进的均值漂移算法

4.2.1 自适应带宽

传统均值漂移算法中带宽是人工确定的固定值，带宽数值大小不仅影响了核函数 K 的作用区域，并且甚至影响着最后的聚类结果。当数据点分布均匀时，最终实验结果不会受到带宽影响。但实际中样本点的分布是不均匀时，人工选取的带宽无法根据像素点分布的情况自动调整，因而无法实现全局最优。当带宽 h 取值较大时，在像素分布集中的区域像素概率密度值比较大且近似相等，这样就会导致相近的像素点在聚类时被合并，在图像中具体表现为欠分割，容易产生边缘信息丢失的问题。当带宽 h 取值较小时，在像素分布稀疏的区域本该属于同一类的数据点会聚类为多类，在图像中表现为过分割。过分割和欠分割都是因为人工选取带宽导致了错误聚类。

本文为了解决上述问题提出了自适应带宽的方法^[49]，重新定义窗宽函数为：

$$h(x_i) = h_0 \times (1 - l(x_i)) \quad (4-7)$$

其中， h_0 为常量， $l(x_i)$ 为归一化后的概率密度函数。该窗函数根据每个像素点概率密度分布的特征求出相应的带宽值，像素点的概率密度不同则适用不同的带宽值：当概率密度值比较大时，可以得到小带宽；当概率密度值比较小时，可以得到密度稀疏区域对应的大带宽。这样，我们可以实现在像素密度分布集中的地方对带宽取值偏小，在像素概率密度分布稀疏的地方使用大带宽。接下来，就可以根据每个像素点的自适应带宽求出新的均值漂移向量函数和样本均值。

4.2.2 新均值偏移向量参数的计算

因为带宽函数发生了改变，此时相应的均值漂移向量和样本均值函数也发生相应地变化。分别将式(4-7)带宽函数代入式(4-5)和(4-6)可得

新的均值漂移向量：

$$M_h(x) = \frac{\sum_{x_i \in I} K\left(\frac{x_i - x}{h_0 \times (1 - l(x_i))}\right) w(x_i) x_i}{\sum_{x_i \in I} K\left(\frac{x_i - x}{h_0 \times (1 - l(x_i))}\right) w(x_i)} - x \quad (4-8)$$

新的样本均值函数为：

$$m_h(x) = \frac{\sum_{x_i \in I} K\left(\frac{x_i - x}{h_0 \times (1 - l(x_i))}\right) w(x_i) x_i}{\sum_{x_i \in I} K\left(\frac{x_i - x}{h_0 \times (1 - l(x_i))}\right) w(x_i)} \quad (4-9)$$

4.3 基于改进算法的 DTI 图像分割

通过 4.2 节可以得到自适应带宽的计算方法，利用自适应带宽可以得到新的均值漂移向量和样本均值，所以本文结合 4.2 节采用改进后的算法对 DTI 图像实现分割，其实现过程如下：

步骤一 读入待分割的 DTI 图像；

步骤二 计算相应 DTI 参数并得到对应的图像；

步骤三 通过 4.2 节得出数据点的自适应带宽 $h(x_i)$ ；

1) 根据读入图像的像素特性求出归一化的概率分布函数 $l(x_i)$ ；

2) 根据窗宽计算式 (4-7) 对所有数据点计算其带宽；

步骤四 利用自适应带宽根据式 (4-9) 计算 $m_{H_i}(x)$ 将其作为均值漂移新的中心点；

步骤五 计算样本均值 $m_{H_i}(x)$ 与带宽内所有样本点之间的差值，即偏移量 $m_{H_i}(x) - x$ ，并判断偏移量与给定阈值 ε 的关系，如果 $(m_{H_i}(x) - x) \leq \varepsilon$ ，跳出循环并将样本均值点作为样本的收敛点，并将带宽内的所有像素点聚为一类。如果 $(m_{H_i}(x) - x) > \varepsilon$ ，则将 $m_{H_i}(x)$ 的值赋给 x 并回到第四步继续执行；

步骤六 输出聚类实现的结果图像。

传统的均值漂移算法在带宽选取上是人为确定的固定值，存在欠分割、效率低和无法实现全局最优的问题。为克服上述存在的弊端，所以本章节改进了原算法。本文算法重新定义了窗函数 $h(x_i)$ ，根据像素点的分布特性求出相应的自适应带宽，这样就可以实现在密度集中处带宽取值较小，在密度稀疏处带宽取值较大。

4.4 实验结果与分析

本文所使用数据是由明尼苏达大学提供。7 幅 DTI 图像所加梯度脉冲的方向分别为：(0 0 0)、(0.707 0 0.707)、(-0.707 0 0.707)、(0 0.707 0.707)、(0 0.707 - 0.707)、(0.707 0.707 0)、(-0.707 0.707 0)，轴向为 58 层，体元大小为 $2\text{mm} \times 2\text{mm}$

$\times 2\text{mm}$, $\text{TE}=95\text{ms}$, $\text{TR}=8.7\text{s}$ 。

本实验首先对第 26、30 和 33 层的 DTI 图像实现了胼胝体的分割实验, 利用带宽自适应的均值漂移算法对 DTI 图像进行分割; 然后依次计算出第 30 和第 33 层 DTI 图像对应的各向异性参数 FA 和 MD, 再利用均值漂移算法对各向异性参数图像进行分割实验, 用来验证改进后算法的准确性。所有的实验均是在 Matlab R2012a 上编程仿真, 在 Windows 7 操作系统, 2.10 GHZ CPU 的 Lenovo 笔记本电脑上仿真实现。

图 4-3(a), (d)和(g)分别是人脑第 26 层, 30 层和 33 层 DTI 图像, 图 4-3(b), (e)和(h)分别为利用改进前的算法得到的第 26 层, 30 层和 33 层胼胝体分割结果, 图 4-3(c), (f)和(i)分别是利用改进后的算法得到的第 26 层, 30 层和 33 层胼胝体实验结果。




图 4-3 第 26、30 层和 33 层 DTI 分割结果

图 4-3(b), (e)和(h)是通过改进前的均值偏移算法得出的实验结果, 实验结果中信息都出现了一定程度的丢失。在图 4-3(b)中, 整个左胼胝体的信息都发生了丢失情况, 本应该属于目标区域的信息被聚类到了背景区域, 出现了错误聚类的情况。在图 4-3(h)中, 感兴趣区域边缘信息出现了丢失, 同样也是受到了固定带宽的影响导致了错误聚类的情況。

图 4-3(c), (f)和(i)分别是利用改进后的算法得到的胼胝体分割结果, 通过对比图 4-3(c)和(b), 我们可以看到图 4-3(c)中胼胝体中的信息都得到了完整地分割, 实现了准确地聚类。通过对比图 4-3(h)和(i), 我们可以看到, 改进后的算法在分割图像的时候同样完整地保留了胼胝体的边缘信息, 对比改进前的算法, 本文的算法在分割上保留了完整地信息, 实现了准确地聚类。

图 4-4(a)和(d)依次是 MD 和 FA 的图像, 图 4-4(b)和(e)分别利用改进前的算法得到的实验结果, 图 4-4(c)和(f)依次是利用改进后的算法得到的胼胝体实验结果。




图 4-4 第 30、33 层 FA 和 MD 图像分割结果

图 4-4(b)利用固定带宽数值去分割 MD 图像, 实验结果中感兴趣区域的部分信息出现了丢失, 图 4-4(e)中同样利用改进前的算法去分割 FA 图像, 实验结果中胼胝体的部分信息出现了丢失。

图 4-4(c)是利用本章改进后算法分割 MD 图像, 对比图 4-4(b)和(c), 利用本

文算法得到的分割结果中，左胼胝体信息没有丢失，胼胝体最终呈现了完整的信息。图 4-4(f)是利用改进后的算法分割 FA 图像的实验结果，对比图 4-4(e)和(f)，在本文算法的分割结果中，胼胝体的边缘信息得到了完整的呈现。

通过以上所有的实验来说，对于 DTI 原始图像和各向异性参数图像来说，利用固定带宽的算法去分割图像，实验结果中的信息总会出现一定程度的丢失，进而出现分割错误的结果。对比与固定带宽的均值漂移算法，本文利用改进后的自适应算法，通过重新定义窗函数，利用图像的概率密度分布去计算带宽，最终的分割结果显示改进后的实验结果中能更好地保留图像的信息，实现了准确地分割。

4.5 本章小结

均值漂移算法无需先验证知识，因此在实验的时候不需要确定最初的中心点。但是传统的均值漂移算法手动地确定固定的带宽，在 DTI 图像聚类时会出现部分信息丢失，聚类错误的缺陷。所以本文通过重新定义窗函数，利用图像的概率密度函数确定带宽值，进而去分割 DTI 图像。

本章节利用改进后的算法分割第 26 层，30 层和 33 层的 DTI 原图像，并分割各向异性参数 MD 和 FA 图像。实验显示胼胝体的信息有了更加完整地呈现，实现了准确地聚类，实验的效果也得到了改善。

第 5 章 DTI 图像的三维重建

DTI 图像的三维重建^[50]是通过将二维图像中提取得到的感兴趣区域进行三维显示的过程。当医生需要从组织的整体去直观地分析某一组织时，往往是通过二维信息的空间想象建模，这样立体化的效果往往不佳，并且容易丢失相关信息。为了解决这一问题，本章通过基于 VTK^[51]的三维重建解决了这一问题。

本章由于是基于 VTK 去实现三维重建，所以首先对 VTK 进行了介绍，详细分析了 VTK 的结构层次和类库含义，同时在对 VTK 类库进行编译时，用到了 Cmake 平台，所以又详细介绍了如何在 Cmake 配置 VTK 环境，之后研究并详细说明了本章所用的面绘制算法：移动立方体算法。由于大部分学者在心脏和肺部的三维重建所做的工作较多，所以本文结合实际的条件，利用人脑的胼胝体数据，通过编写相应代码，在 VS 2010 的开发平台上实现了三维重建的过程。

5.1 三维重建的基本过程

本章图像三维重建的基本过程如图 5-1 所示，首先将图像转化为计算机可以直接处理的格式并存储。在开始下一步的处理之前对图像做预处理，通过对图像做滤波操作，去除图像中的噪声，以便使显示效果最佳。去除噪声的影响之后，对图像进行分割处理，将我们感兴趣的区域提取出来，对提取出的感兴趣区域构造体数据，作为我们三维重建的源数据。最后，利用三维可视化平台 VTK 的重建算法^{[52][53]}对输入的体数据进行处理，最终显示重建后的三维立体数据。

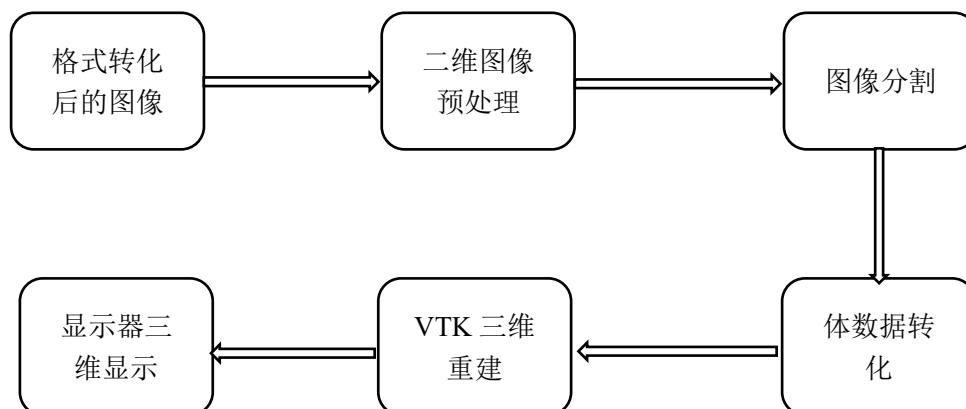


图 5-1 三维重建基本过程

5.2 可视化类库 VTK

5.2.1 VTK 简介

VTK^{[54][55]}作为一种开源可视化的类库，由美国著名公司 Kitware 推出，由于其在可视化方面的强大表现，取得了普遍地使用。VTK 中类库是基于面向对象三维可视化算法的封装，用户可以根据需要编写和调用相关代码实现相应的功能。VTK 的内核是使用 C++ 语言实现，但是开发人员同样可以使用其他编程语言调用 VTK 中的类库，比如 Java、Python 等。并且 VTK 类库还支持跨平台，如 Windows、Linux 系统都可以应用，具有很强地可移植性，这两大优点再结合其可以并行处理极大地缩短了开发的时间，提高了开发的速度。

VTK 从发布以来，通过不断地更新和完善成为了非常强大且应用广泛的图像处理类库，在科研数据的三维可视化方面扮演了重要的角色，可以帮助研究者去理解那些高维和及其复杂的数据信息，更加方面地开展科研等各项工作。

5.2.2 VTK 类库组成介绍

VTK 在层次结构方面分为两类，分别为核心层和解释层。在系统层次方面分为三层：操作系统层、VTK 层、应用层。VTK 的体系结构图如下所示：




图 5-2 VTK 的体系结构

VTK 在核心层通过 C++ 封装了常用的图像处理算法，通过提供相应的编程接口，可以在解释层通过 Python 或 java 代码进行调用，同时 VTK 作为操作系统和应用层的中间层，并且为其提供了不同的接口，在应用层和操作系统层之间更好地交互操作。

对于 VTK 层次结构中的 C++ 类库，按照其类的功能不同将其分为以下几类：

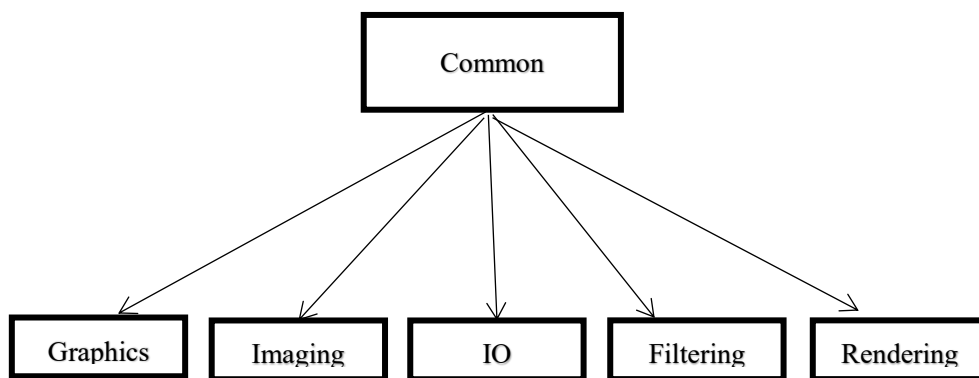


图 5-3 VTK 功能类划分

在图 5.3 中，Common 代表全部的公共基类，Graphics 代表处理和变换图形的类，Imaging 代表数字图像处理算法类集合，IO 类作为输入输出流，实现不同数据的读入和写出，Filtering 类用来处理各种不同格式图像之间的转换，Rendering 类代表的是最终绘制数据并在窗口显示。所有箭头的代表所有的类都是从 Common 继承而来。

5.2.3 VTK 可视化流程

VTK 三维可视化是通过管道的方式实现，逐步对数据进行处理实现三维可视化的效果，其中可视化的一条管道主要分为两个部分：可视化和渲染管线。如图 5.4 所示：

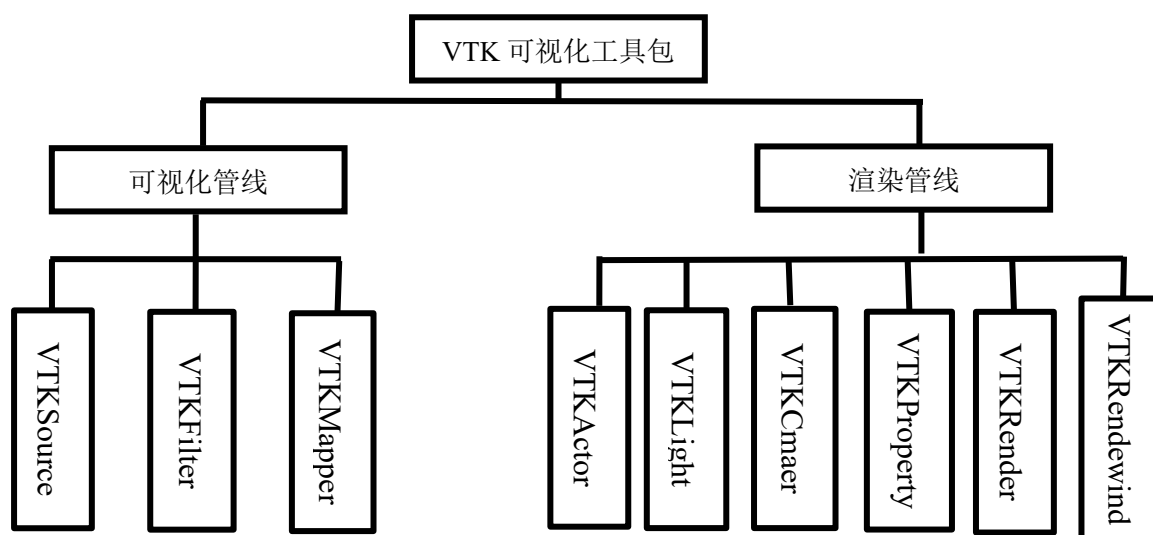


图 5-4 VTK 可视化管道图

对于可视化管道线中包含三个类库：VTKSource, VTKMapper 和 VTKFilter，VTKSource 类库主要的作用是指数据源头的开始，负责获取或者创建数据。

VTKFilter 类库提供的主要是对数据的预处理功能，包括对源数据的去噪或者增强等操作。VTKMapper 类库则作为可视化管线的结束和渲染管线的开始，通过将可视化管线处理的数据转化为渲染管线的数据格式，在两个管线之间有着衔接的作用。在可视化管线中，主要是建立一个 Data Pipeline 对数据进行处理，而建立 Pipeline 的过程就是实现 VTKSource，VTKMapper 和 VTKFilter 三者的连接，VTKSource 建立数据或者读取数据之后，VTKFilter 会对数据进行相关的处理，将从 VTKSource 端得到的数据转化被算法直接处理的格式，最后 VTKMapper 将从 VTKSource 端输出的数据全部转化为几何数据，并且三种类库都为相应的数据转化提供了接口，可以通过实现特定的功能调用相应的接口，实现处理特定的数据格式。

对于渲染管线包括六个管线：

VTKActor: 主要是指显示器中呈现的显示角色或者所绘制的实体，可类比话剧舞台中的演员。

VTKLight: 主要是指绘制器中的光效，包括光强，光的颜色和光线的位置等，不过这些光效只是作用于 3 维立体模型的显示。

VTKCamera: 主要是通过在显示器投影图像时设置视角的位置，视角的角度和焦点等，这就可比拟为话剧舞台中观众的眼睛，处于不同的位置或者角度所观察到效果是不同的。

VTKProperty: 用来设置角色的属性，比如颜色，质感等呈现的不同外观，类比为舞台中演员不同颜色的着装。

VTKRender: 其主要功能实现对 VTKLight、VTKActor、VTKProperty 的管理，同时衔接绘图的引擎功能和绘制窗口(VTKRenderWindow)。

VTKRenderWindow: 主要功能是对所渲染数据对象，即要显示图像的绘制窗口或所呈现的视窗。




图 5-5 VTK 绘制实例

上图通过一个棱锥的三维重建显示了上述部分类库的对应关系。

通过 VTK 可视化的两条管线的协作, 实现将三维数据的绘制, 基于两条管线的绘制流程如图所示:

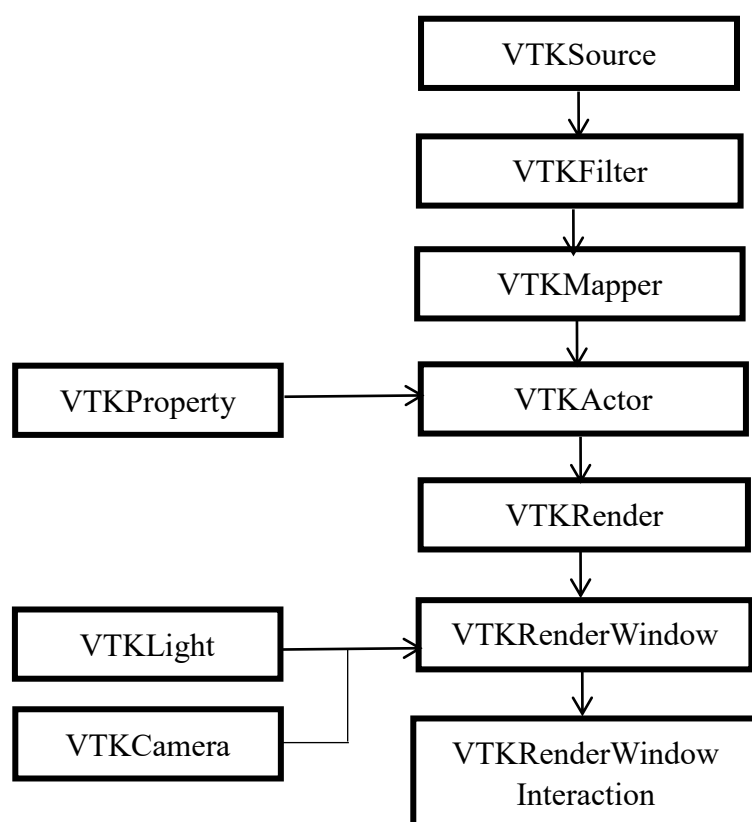


图 5-6 VTK 的可视化流程图

5.3 CMAKE 与 VTK 配置

5.3.1 CMAKE 简介

Cmake^{[56][57]}作为一种可跨平台的构建工具, 比如在 Windows 系统、Linux/unix 系统等, 作为一种常用的编译工具, 广泛应用于项目的构建和管理。利用 Cmake 可以根据在不同的平台生成不同的配置文件。其中对于 Windows 系统, 可以利用 Cmake 在 Visual Studio 中生成相应的项目文件, 如生成.sln 文件等。Cmake 发布于 1999 年, 最初是美国政府部门资助的 Insight Toolkit(ITK)项目中的一部分, 由于 ITK 的设计目标就是实现跨平台使用, 为了满足这一需求, 同时还要作为一个方便且容易使用的构建工具, Cmake 就这样孕育而生。通过多年的发展, Cmake 现在已经趋于成熟的状态。VTK 最初的构建工具是 PCMake, 由于 Cmake 的不断发展和成熟取代 PCMake 的位置, 慢慢成为了 VTK 的构建工具。对于工程的

构建, Cmake 实现方法相对容易, 只需要将写好相应的 CMakeLists 的代码文档, 存储格式为文本文档(txt)即可。同时, Cmake 有两种不同的构建方法: 一种是 Cmake 在编译的时候, 源文件和生成的二进制文件放在同一个绝对路径之下的目录中, 第二种构建方法是 Cmake 在编译的时候两个文件处于不同的绝对路径之下目录中。

5.3.2 VTK 的配置过程

在进行 Cmake 和 VTK 配置之前, 可分别在官方网站下载相关版本的安装包和压缩文件并同时安装好 Cmake 软件, 此处配置过程我们使用 Cmake 的第一种构建方法, 即将源文件和生成的二进制文件放在同一个文件目录之下。本文我们提前设置好两个目录路径文件名, 其中源文件具体路径是 F:\VTK\MC, 二进制的编译文件对应的路径是 F:\VTK\MC_bin。如下图所示:

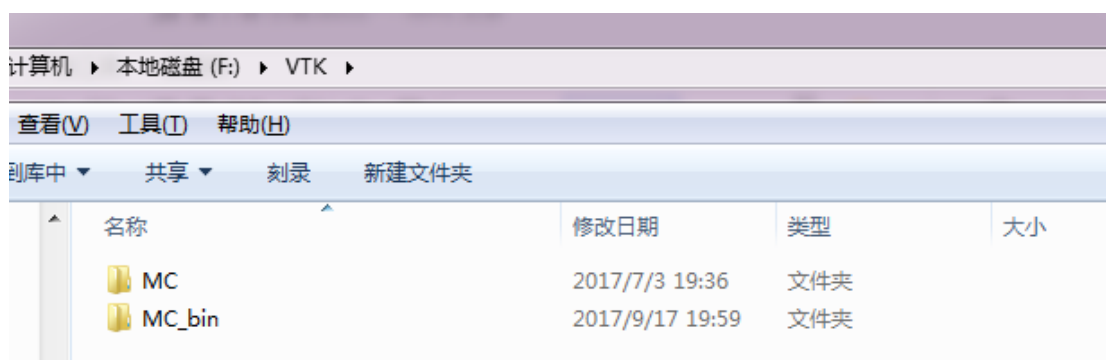


图 5-7 Cmake 的第一种构建方式

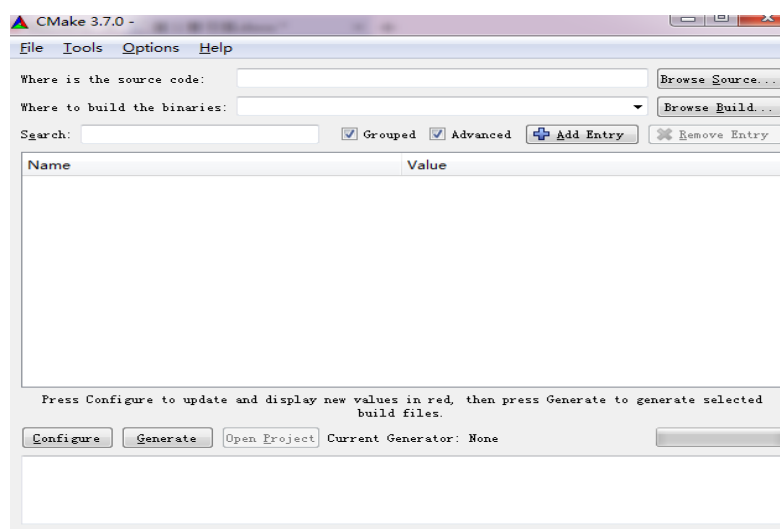


图 5-8 Cmake 的软件截图

创建源文件和二进制文件的路径之后，把下载好的 VTK 压缩包分别放在两个不同的文件目录之中。其中将 VTK_zip 解压到 F:\VTK\MC 路径之下，将 VTKData_zip 解压到 F:\VTK\MC_bin 路径之下。建立好相应的文件和路径之后，接下来开始具体的配置项目，上图为 Cmake 的软件截图。

在 source-code 位置处读取 F:\VTK\MC 中的内容，在 build the binaries 处读取 F:\VTK\MC_bin 之中的内容，Cmake 读取两个文件目录之后，点击 configure 和 advanced 按钮，在弹出的界面框中根据本机选择相应的集成开发环境，本文选择的是 Visual Studio 10 win64 的版本，如下图示：

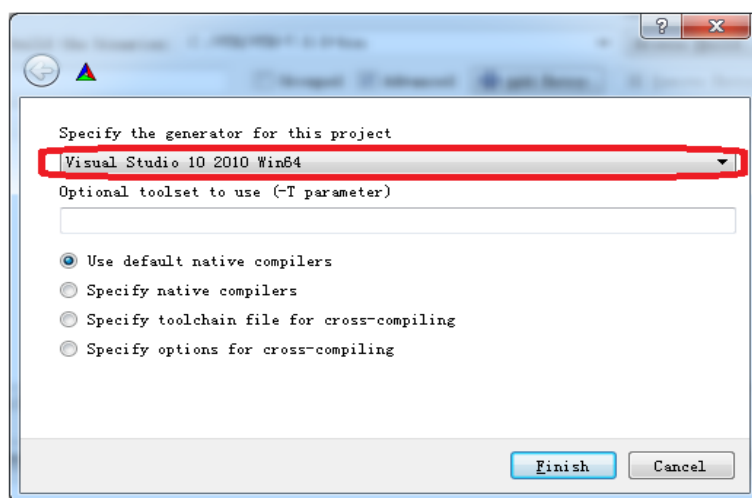


图 5-9 开发环境的选择

在选择好相应的配置环境后，在弹出的对话框中勾选相应的选项，然后继续点击 Configure 和 Generate 选项，对话会分别提示 Configuring done 和 Generate done，表示全部的配置过程已经完成，最终配置完成的截图如下：

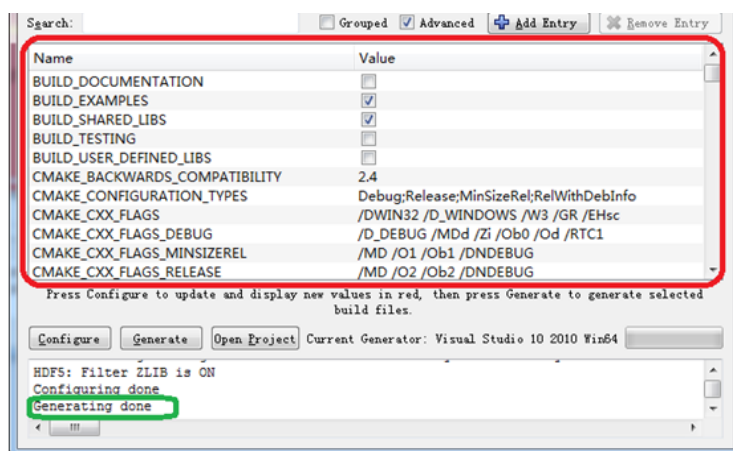


图 5-10 配置完成结果图

5.4 三维重建的基本方法

5.4.1 等值面绘制

等值面绘制^{[58][59]}是用户通过设置阈值,将数据点的属性(比如像素值)和阈值进行比较,对比较后的结果进行目标渲染,最终是基于表面的几何图元显示,通常的表面特征一般选择三角形面片进行拼接拟合,再通过选取的渲染特效、光照模型重建出实际效果的三维立体图像。面绘制对感兴趣区域绘制的效果比较好,通常是将待重建的区域先在二维切片进行分割,将分割好的二维切片再进行表面重建。面绘制由于直接对感兴趣的区域进行三维重建,在处理数据上会表现出比较高的效率。面绘制技术经过长时间的发展,根据面绘制技术对基本单元的处理不同,可以分为两种:基于切片和基于体素的面绘制重建。

1 基于切片的面绘制

基于切片的面绘制基本思想是提前设置好阈值,通过阈值提取每层切片的轮廓线,然后拼接所有切片的轮廓线,最终拟合出三维立体图形表面。随着医学图像所需精度的增加,切片之间轮廓线的拼接模糊性已经不适应发展的需求。

2 基于体素的面绘制

基于体素的面绘制基本思想是先在邻近的切片之中每层选取若干个样本点,两层数据点之间所包含的区域称之为体素,然后在该区域的内部构建若干个等值面,对构建好的等值面集进行处理,最终形成立体模型。一般基于体素的面绘制分为:移动立方体方法(Marching Cubes, MC)和剖分立方体算法。

在三维可视化的过程中通常利用 8 个点构成体素,也就是从两个相邻的断层图像中分别选取 4 个数据点构成体素模型,体素模型如图 5-11 所示:




图 5-11 体素模型

数据点在 x, y, z 轴方向每次采样的间距都是相同的。

1) 移动立方体方法

MC 算法^[60]作为一种面绘制算法，算法在提出之时得到了广泛的应用，该算法的核心是从二维断层图像之间构建的体素里面提取等值面，所以又称之为“等值面提取算法”。

MC 算法假设体素模型中数据点变化是连续的，当给定阈值之后，所有体素模型中每个数据点的像素值将和阈值大小进行比较，当每个数据点像素值都比阈值或者都比阈值小时，此时说明在此体素模型之中没有等值面。当对于体素模型中同一条边的来说，如果给定的阈值大于其中一个数据点，同时小于另外一个数据点，此时等值面和此条边有交点，说明当前模型具有等值面。

进一步地，我们对体素模型中 8 个顶点的状态进行划分，当体素模型中的数据点的数值大于给定阈值时，将该样本点的状态标记为‘1’，如果体素模型中样本点的数值小于给定阈值，则将该数据点的状态标记为‘0’。因为模型中 8 个数据点，每个数据点都有‘1’和‘0’形态，所以总共存在 $2^8 = 256$ 中状态，根据互补对称性，可以将其简化为 128 种状态，再通过旋转不变性的特点，最终的状态可以简化为 15 种。如图 5-11 所示，展示了体素模型中 8 个顶点的状态，其中黑色圆点表示状态‘1’，白色圆圈表示状态‘0’。




图 5-12 15 种状态的体素模型

第一种状态是给定阈值小于所有的数据点，在体素模型中没有构建等值面。第二种状态存在一个等值面，利用三角形面片将体素模型分为两部分。其余的状态也是存在一个或多个的等值面片集。

我们对总共的 256 种状态建立体素状态索引表，通过状态索引表，当输入数据源时，对比阈值和数据值的大小关系可以确定体素模型的状态。体素状态索

引表如图 5-12:

索引	旋转	体素状态
----	----	------

图 5-13 体素状态索引表

其中体素状态是由 4 位二进制 '0', '1' 状态码组成的 15 种状态, 旋转中存放的是 1 位二进制编码, 索引中存放的是 8 位二进制编码, 用来分别表示 8 个顶点的 '0', '1' 两种状态, 对于索引, 其结构如图 5-14 所示:

A1	A2	A3	A4	A5	A6	A7	A8
----	----	----	----	----	----	----	----

图 5-14 索引编码表

当明确了体素的状态之后, 如果此时体素状态中没有等值面片, 不需要进行任何计算, 但当模型中存在等值面片时, 需要计算三角形面片与当前模型的交点坐标, 同时还需计算其法向量。对于交点坐标的计算, 存在两种方法: 线性差值和中心选择。

对于线性插值法, 当给定的等值面和体素存在交点时, 可以利用与交点位于同一条直线上的两个顶点坐标进行求解坐标和法向量, 计算公式如下所示:

$$\vec{O} = \vec{O}_1 + \frac{(C - Z_1)(\vec{O}_2 - \vec{O}_1)}{(Z_2 - Z_1)} \quad (5-1)$$

$$\vec{F} = \vec{F}_1 + \frac{(C - Z_1)(\vec{F}_2 - \vec{F}_1)}{(Z_2 - Z_1)} \quad (5-2)$$

其中, \vec{O} 表示的是等值面和模型的交点坐标向量, C 表示给定的阈值大小, Z_1 和 Z_2 分别表示的是体素中两个数据点的像素值大小, \vec{O}_1 和 \vec{O}_2 分别表示体素中两个顶点的坐标向量, \vec{F} 表示的是等值面片的法向量, \vec{F}_1 和 \vec{F}_2 分别表示体素中两个顶点的法向量。

不同于线性差值法, 中心选择法是直接利用体素中两个顶点的法向量和坐标值进行求平均值计算面片的法向量和坐标值, 计算公式如下所示:

$$\vec{O} = (\vec{O}_2 - \vec{O}_1) / 2 \quad (5-3)$$

$$\vec{F} = (\vec{F}_2 - \vec{F}_1) / 2 \quad (5-4)$$

2) 剖分立方体算法

对于剖分立方体算法, 其算法主要思路为: 首先设置好阈值的大小, 通过遍

历所有的体素，分别对比每个体素模型与阈值的关系，当体素模型中每个顶点的灰度值都比阈值的数值大或者小时，则说明体素没有构建等值面片，对该体素模型无需处理。当模型中顶点的数值中既有比阈值大，同时也有比阈值小的情况，此时说明等值面片与当前模型存在交点。然后对存在等值面的体素模型进行处理，由于最终的三维模型要投影在显示器上面，如果体素模型的大小比显示器中的单位像素大，此时需要将每个体素模型进行分解，分解时按照坐标轴的三个方向进行剖分，直到分解后的体素模型小于或者等于视平面的单位像素，最终通过渲染显示在视平面上。其算法流程图如下所示：

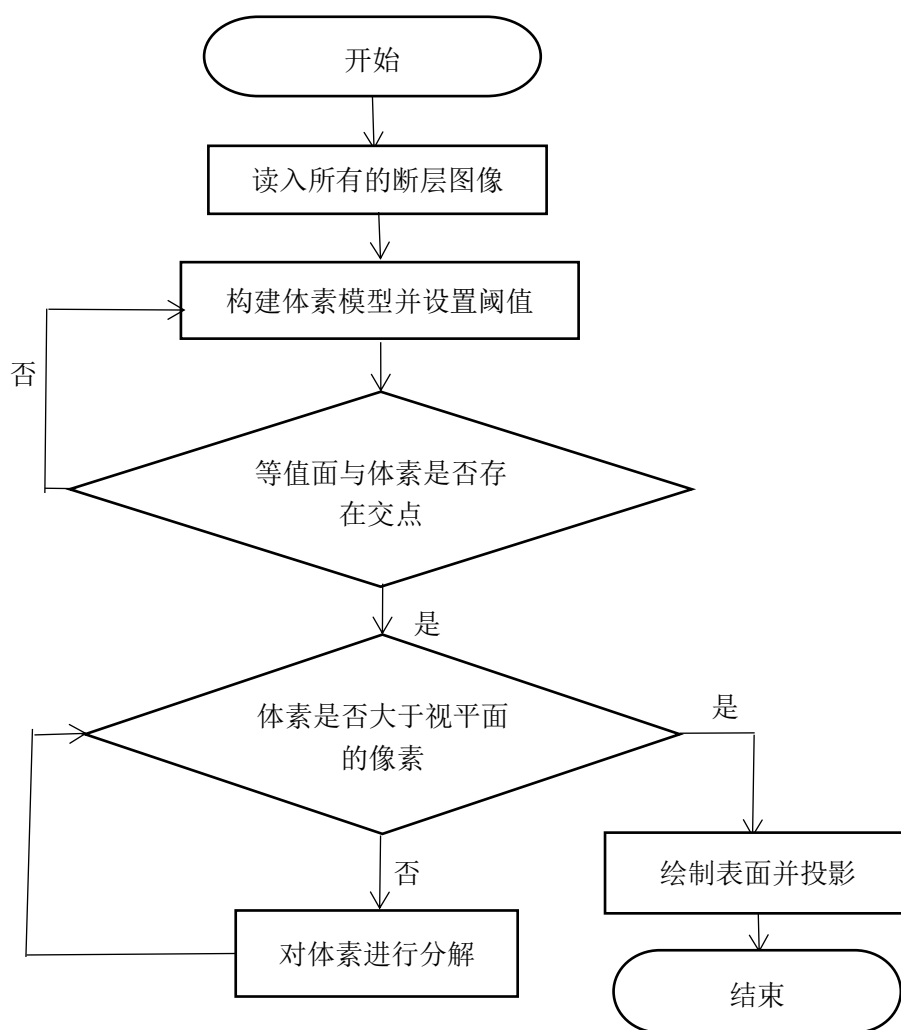


图 5-15 剖分立方体算法流程图

对于密度比较高的体素模型，可以通过分解体素模型，此时无需通过差值的方式去计算等值面片，速度相对于 MC 算法偏快，但是剖分立方体算法最终分解的过程中是采用体素中心作为三角形面片，没有通过差值的方式精确计算，所以最终的重建效果会比 MC 算法偏差。

5.5 重建过程及结果

5.5.1 MC 算法重建过程

上一小节完成了对 VTK 的配置, 本小节将基于 VTK 利用移动立方体算法实现对图像的三维绘制, 具体实现过程如下:

(1) 读取源数据的图像序列。本小节的源数据为第四章利用均值漂移算法分割得到的图像序列, 由于图像处理已将图像转化为 BMP 的格式, 所以创建图像 VTKBMPReader 的类对象, 设置好类对象后同时设置图像的绝对路径地址, 即可正确读取源数据。在第四章实现了对 58 张图像序列的分割, 所以重建的源数据为 58 张连续的二维图像序列, 下图为 58 张图片序列中选取的 6 张图片。




图 5-16 面绘制的部分数据源

样本点的抽取。为了加快算法处理的速度,可以利用采样处理,通过在数据点的三个方向均匀取值,可以减少数据处理量,此时我们可以通过 `VTKImageShrink3D` 类中的 `SetShrinkFactors(int i, int j, int k)` 方法去设置,其中 `i, j, k` 就依次对应 `x, y` 和 `z` 轴的方向,我们可以通过分别设置三个方向上的数值大小来实现均匀采样数据点。

(2) 减少等值面片。在面绘制中,通常等值面的形状会设置为三角形面片,通过设置相应的阈值,会产生一定数量的等值面片,但是当图片的序列逐渐增大时,数据处理的速度变得非常慢,此时,可以相应地减少所构建面片的数目。我们可以利用 VTK 类库中的 `VTKDecimatePro` 类减少读取等值面片的数量,通过创建对象利用该类中的 `SetTargetReduction` 方法设置对应的参数。

(3) 图像平滑。我们在第三步对减少了部分的等值面片,这样会使绘制的表面出现顶点变得不均匀,进而使得绘制的表面变得不光滑,最终也会影响绘制效果,所以非常有必要对图像实施平滑操作。我们可以利用 `VTKSmoothPolyDataFilter` 类实现对绘制的表面的平滑处理,使最终的绘制表面更加光滑。

(4) 生成映射(Mapper)。我们可以调用 VTK 中的 `VTKSmoothPolyDataFilter` 类,并利用该类生成映射对象,再通过映射对象将多边形的数据转化为图形数据。

(5) 生成演员(Actor)。我们可以调用类库中的 `VTKActor` 类,通过该类生成 Actor 对象,并利用 Actor 对象中的 `setMapper()` 方法将步骤 5 生成的 Mapper 对象添加到 Actor 对象中,同时使用 `AddActor()` 方法在绘制对象中加入 Actor 对象。

(6) 生成 render 对象。利用类库中的 `VTKRender` 生成 render 绘制对象,生成的代码为 `VTKRenderer render = VTKRenderer::New()`

(7) 生成窗口对象 `RenWin`。利用 `VTKRenderWindow` 类绘制窗口对象 `RenWin`,同时可以利用该类中 `SetSize()` 方法调整窗口尺寸大小,并在绘制窗口中加入生成的对象 `render`。

(8) 生成交互的对象,利用类库中的 `VTKRenderWindowInteractor` 生成交互对象,同时利用该类的 `SetRenderWindow()` 方法在绘制的窗口中加入生成的交互对象。

(9) 输出对象。利用类库中的 `VTKPolyDataWriter` 实例化输出对象,同时利用该类中的 `SetInput()` 方法对将要输出的对象进行设置。若想重命名输出的文件名,可以利用该类中的 `SetFileName` 方法进行设置,最终通过 `write()` 方法对其进行输出。

上述三维重建的步骤利用管道的形式进行实现,通过流水线的形式贯穿和实现重建的步骤,所以本文实现 DTI 胼胝体图像三维重建的流程图如下:

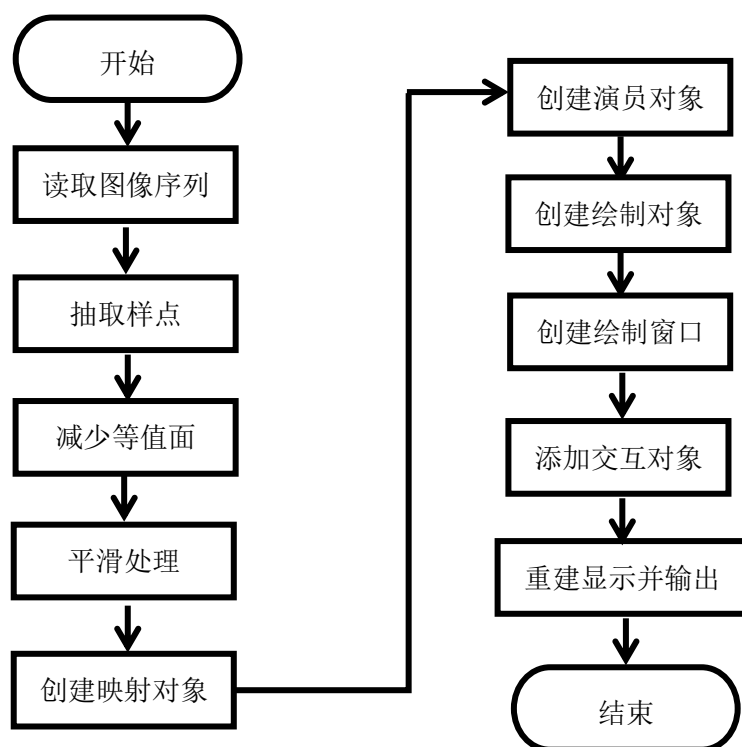



图 5-17 本文三维重建实现流程图


5.5.2 三维重建结果

本章的三维重建过程是基于 Windows 的操作系统，开发平台为 Cmake 和 VS 2010，通过第四章得到的分割结果作为本实验的数据源，采用 MC 算法实现图像的三维绘制。最终的重建结果可以从多个方向对胛胝体的三维模型进行研究，同时具有比较好的交互性。部分绘制结果如图 5-18 所示：




(a) 胛胝体后视图


(b) 胛胝体俯视图



(c) 胼胝体侧视图




(d) 胼胝体侧视图



(e) 胼胝体放大操作



(f) 胼胝体缩放操作



(g) 胼胝体伪色彩色彩一



(h) 胼胝体体伪色彩二

图 5-18 移动立方体算法三维重建方法

图 5.18 显示了基于 MC 算法三维重建的绘制图像，由图可见，MC 算法比较好的还原出了胼胝体的结构纹理信息。其中图 5.18(a-d)从四个不同的角度展示了胼胝体的重建结果图，图 5.18(e)展示的是重建结果的拉伸操作，图 5.18(f)展示的是胼胝体的缩放操作，图 5.18(g)和(h)展示的是对胼胝体绘制利用不同的伪色彩。实验结果中通过三维的角度还原了胼胝体的结构信息，基于三维重建呈现出的组织信息，医生可以实现虚拟解剖，对脑内组织有更加清晰和直观地认识。因此，基于 VTK 的三维重建具有重要的研究价值和现实意义。

5.6 本章小结

本章研究了面绘制算法，并主要分析了面绘制的 MC 算法，并基于 VTK 实现了移动立方体算法，并完成了对人脑胼胝体部位的绘制。三维绘制最终目的是可以实现研究者从不同角度对组织的研究，面绘制是通过构建等值面片，然后对等值面片进行渲染处理，最终实现绘制的效果。由于面绘制一些常用的类库都封装在 VTK 中，所以本章又详细介绍了 VTK 类库的层次结构，并从重建流程的角度分别对 VTK 的类库做了相应地说明。最后结合 CMAKE 具体介绍了 VTK 的配置过程，同时基于 VTK 利用移动立方体算法实现了对胼胝体的三维重建，并从不同的角度对胼胝体进行了展示。

第 6 章 总结与展望

本文主要对 DTI 图像中的胼胝体进行了分割和三维的重建工作, 首先对扩散张量成像的原理进行了介绍, 其后基于区域对图像的分割算法进行了说明, 并对 FCM 和均值漂移算法做了详细地研究, 结合最大最小距离算法的模糊 C 均值算法, 基于改进带宽函数的均值漂移算法, 利用三维重建算法对胼胝体区域进行了重建, 所以本文从以下几个方面进行了研究:

1) DTI 图像成像原理的研究与各向异性参数的计算

不同于传统的成像方式, DTI 的成像中加入了方向的信息, 所以组织内的水分子在扩散时候与呈现出了各向异性的特性。结合 DTI 特有的成像特点, 对其成像原理进行了研究, 利用 DTI 中重要的张量矩阵信息求出三个不同的特征值, 三个不同大小的特征值决定了水分子的扩散形式, 同时利用三个不同的特征值求出相应的各向异性参数值。接下类, 利用 DTI 图像和各向异性参数为接下来的分割算法和三维绘制提供准备工作。

2) 图像分割与 FCM 算法

对于分割首先通过集合的概念引入了图像分割的有关概念, 主要分析了一些常用的区域分割算法: 阈值分割算法和区域生长算法, 具体介绍了这两种算法的原理及其适用的领域, 同时结合医学图像自身的特性, 引入了 FCM 算法, FCM 在最初中心点上为随机选取, 由于最终的结果依赖于最初中心点, 所以本文改进 FCM 算法, 通过引入最大最小距离确定稳定的最初中心点, 再利用 FCM 对 DTI 图像进行实验可以得到完整的胼胝体区域。

3) 改进的均值漂移算法

均值漂移算法通过漂移带宽寻找密度最大值处, 这是一个不断迭代的过程, 不需要先验知识, 在算法上的稳定性方面具有一定的优势。但是传统的均值漂移算法在带宽上是人为选取, 存在一定的缺陷, 带宽无法根据像素点的分布情况自动调整带宽的大小。所以本文对带宽函数进行改进, 将像素点引入带宽函数, 最终可以通过像素点的疏密情况自动确定带宽的大小。利用改进后的算法对 DTI 图像分割, 实验结果中可以得到胼胝体区域比较好的实验效果。

4) 基于 VTK 的三维重建

对于三维重建, 本文详细研究了等值面绘制算法, 等值面绘制通过对断层图像进行处理, 在两个断层图像之间构建体素模型, 通过设定阈值, 在体素模型中构建等值面片, 对等值面片进行渲染实现三维重建。之后本文并基于 VTK 实现

了面绘制算法，在详细介绍了 VTK 的层次结构之后，基于 VTK 的管道方式利用分割好的膀胱体区域实现了三维绘制，并从多个三维的角度展示了膀胱体区域。

对于本文的分割算法和三维重建还存在一些我需要继续努力的地方，具体如下：

1) 对于 FCM 算法，本文通过加入最大最小距离算法，但是 FCM 算法中的数据点和每个聚类中心都存在一定的权重关系，同时容易将噪声点引入，为此还需要考虑空间信息，以减少噪声，提高算法的鲁棒性。

2) 本文基于 VTK 实现了面绘制算法，面绘制算法在某些方面也存在一定的缺点，算法结果中缺失了内部的某些细节信息，所以未来的研究工作可以考虑加入体绘制算法，实现两种算法的结合体现更多的细节信息。

3) 由于面绘制内存需求比较小，所以面绘制的速度比较快，但是当面绘制的数据量逐渐增大时，此时可能考虑对算法的运行效率进行优化，未来工作可以通过减少一定等值面片的构建来提升一定的速度。此外，在未来的研究可以尝试加入更多的交互操作，并取得更好地体验。

参考文献

- [1] 张相芬. DTI 图像去噪方法研究[D]. 上海: 上海交通大学电子信息与电气工程学院, 2008.
- [2] Ali H, Elmogy M, El-Daydamony E, et al. Multi-resolution mri brain image segmentation based on morphological pyramid and fuzzy c-mean clustering[J]. Arabian Journal for Science and Engineering, 2015, 40(11): 3173-3185.
- [3] Pei H X, Zheng Z R, Wang C, et al. D-FCM: Density based fuzzy c-means clustering algorithm with application in medical image segmentation[J]. Procedia Computer Science, 2017, 122: 407-414.
- [4] Ariyo O, Zhi-guang Q, Tian L. Brain MR Segmentation using a Fusion of K-Means and Spatial Fuzzy C-Means[J]. DEStech Transactions on Computer Science and Engineering, 2017 (csae).
- [5] 张辉, 朱家明, 吴杰. 基于模糊核聚类的双水平集医学图像分割[J]. 无线电通信技术, 2016, 42(4): 33-37.
- [6] 张保威, 钱慎一, 宋宝卫. 改进 FCM 在医学图像分割中的应用[J]. 计算机工程, 2012 (2012 年 14): 193-195.
- [7] 宋国权, 李金锋. 基于聚类算法的脑部 MR 图像分割[J]. 中国医疗设备, 2017 (2017 年 01): 26-29.
- [8] Wang J, Thiesson B, Xu Y, et al. Image and video segmentation by anisotropic kernel mean shift[J]. Computer Vision-ECCV 2004, 2004: 238-249.
- [9] Chuang K S, Tzeng H L, Chen S, et al. Fuzzy c-means clustering with spatial information for image segmentation[J]. computerized medical imaging and graphics, 2006, 30(1): 9-15.
- [10] McClymont D, Mehnert A, Trakic A, et al. Fully automatic lesion segmentation in breast MRI using mean-shift and graph-cuts on a region adjacency graph[J]. Journal of Magnetic Resonance Imaging, 2014, 39(4): 795-804.
- [11] 赵胜男, 王文剑. 融合 SVM 和快速均值漂移的图像分割算法[J]. 小型微型计算机系统, 2017, 38(7): 1614-1618.
- [12] Loizou C P, Papacharalambous C, Samaras G, et al. Brain Image and Lesions Registration and 3D Reconstruction in Dicom MRI Images[C]//Computer-Based Medical Systems (CBMS), 2017 IEEE 30th International Symposium on. IEEE, 2017: 419-422.
- [13] D'Agostino D, Seinstra F J. A parallel isosurface extraction component for visualization pipelines executing on GPU clusters[J]. Journal of Computational and Applied Mathematics, 2015, 273: 383-393.
- [14] 李泽宇, 陈一民, 赵艳, 等. 基于改进光线投影算法的医学图像三维重建[J]. 计算机应用研究, 2017, 34(12): 3866-3868.
- [15] 张锡英, 孟繁平, 邱兆文. 基于断层扫描数据的心脏三维重建[J]. 重庆理工大学学报: 自然科学版, 2016, 30(12): 102-107.
- [16] 武力, 张冰洋. 基于 VTK 的人体肺部可视化面绘制[J]. 中医临床研究, 2014, 6(36): 25-27.
- [17] 唐振禹, 吕晓琪, 任国印. 基于 GPU 加速的改进的光线投射算法研究[J]. 现代电子技术

术, 2016, 39(21): 56-60.

[18] 李定川, 李勤瑶. 计算机核磁共振成像技术研究[J]. 影像技术, 2010 (5): 14-18.

[19] 刘旭红, 张乾营, 王伟. Siemens Skyra 3.0T 磁共振仪故障排除二例[J]. 磁共振成像, 2016, 7(07): 524-526.

[20] 盛玉奇. 基于卟啉和二茂铁的新型自组装纳米磁共振造影剂的合成和性能研究[D]. 浙江大学, 2012.

[21] 蔡梦臣. 扩散张量成像关键技术研究[D]. 天津大学, 2012.

[22] Chung S W, Lu Y, Henry R G. Comparison of bootstrap approaches for estimation of uncertainties of DTI parameters[J]. NeuroImage, 2006, 33(2): 531-541.

[23] 任津瑶. 扩散张量成像检测阿尔茨海默病脑白质变化[D]. 天津医科大学, 2010.

[24] Westin C F. Geometrical diffusion measures for MRI from tensor basis analysis[J]. Proc. ISMRM'97, 1997.

[25] Westin C F, Maier S E, Mamata H, et al. Processing and visualization for diffusion tensor MRI[J]. Medical image analysis, 2002, 6(2): 93-108.

[26] Arbelaez P, Maire M, Fowlkes C, et al. Contour detection and hierarchical image segmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2011, 33(5): 898-916.

[27] Boykov Y Y, Jolly M P. Interactive graph cuts for optimal boundary & region segmentation of objects in ND images[C]//Computer Vision, 2001. ICCV 2001. Proceedings. Eighth IEEE International Conference on. IEEE, 2001, 1: 105-112.

[28] Zhu S, Xia X, Zhang Q, et al. An image segmentation algorithm in image processing based on threshold segmentation[C]//Signal-Image Technologies and Internet-Based System, 2007. SITIS'07. Third International IEEE Conference on. IEEE, 2007: 673-678.

[29] Jiang H Y, Si Y, Luo X. Medical image segmentation based on improved Otsu algorithm and regional growth algorithm[J]. JOURNAL-NORTHEASTERN UNIVERSITY NATURAL SCIENCE, 2006, 27(4): 398.

[30] Cuevas E, Zaldivar D, Pérez-Cisneros M. A novel multi-threshold segmentation approach based on differential evolution optimization[J]. Expert Systems with Applications, 2010, 37(7): 5265-5271.

[31] Hassanzadeh T, Vojodi H, Moghadam A M E. An image segmentation approach based on maximum variance intra-cluster method and firefly algorithm[C]//Natural computation (icnc), 2011 seventh international conference on. IEEE, 2011, 3: 1817-1821.

[32] Madeiro J P V, Cortez P C, Oliveira F I, et al. A new approach to QRS segmentation based on wavelet bases and adaptive threshold technique[J]. Medical engineering & physics, 2007, 29(1): 26-37.

[33] Tang J. A color image segmentation algorithm based on region growing[C]//Computer engineering and technology (iccet), 2010 2nd international conference on. IEEE, 2010, 6: V6-634-V6-637.

[34] Tremeau A, Borel N. A region growing and merging algorithm to color segmentation[J]. Pattern recognition, 1997, 30(7): 1191-1203.

[35] Pham D L, Xu C, Prince J L. Current methods in medical image segmentation[J]. Annual review of biomedical engineering, 2000, 2(1): 315-337.

[36] Chuang K S, Tzeng H L, Chen S, et al. Fuzzy c-means clustering with spatial information for image segmentation[J]. computerized medical imaging and graphics, 2006, 30(1): 9-15.

- [37] Chen S, Zhang D. Robust image segmentation using FCM with spatial constraints based on new kernel-induced distance measure[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2004, 34(4): 1907-1916.
- [38] Szilagyi L, Benyo Z, Szilágyi S M, et al. MR brain image segmentation using an enhanced fuzzy c-means algorithm[C]//Engineering in Medicine and Biology Society, 2003. Proceedings of the 25th Annual International Conference of the IEEE. IEEE, 2003, 1: 724-726.
- [39] Johnson M E, Moore L M, Ylvisaker D. Minimax and maximin distance designs[J]. Journal of statistical planning and inference, 1990, 26(2): 131-148.
- [40] Cheng Y. Mean shift, mode seeking, and clustering[J]. IEEE transactions on pattern analysis and machine intelligence, 1995, 17(8): 790-799.
- [41] Comaniciu D, Meer P. Mean shift analysis and applications[C]//Computer Vision, 1999. The Proceedings of the Seventh IEEE International Conference on. IEEE, 1999, 2: 1197-1203.
- [42] Comaniciu D, Ramesh V, Meer P. Real-time tracking of non-rigid objects using mean shift[C]//Computer Vision and Pattern Recognition, 2000. Proceedings. IEEE Conference on. IEEE, 2000, 2: 142-149.
- [43] Fukunaga K, Hostetler L. The estimation of the gradient of a density function, with applications in pattern recognition[J]. IEEE Transactions on information theory, 1975, 21(1): 32-40.
- [44] Fukunaga K. Introduction to statistical pattern recognition[M]. Academic press, 2013.
- [45] Comaniciu D, Ramesh V, Meer P. The variable bandwidth mean shift and data-driven scale selection[C]//Computer Vision, 2001. ICCV 2001. Proceedings. Eighth IEEE International Conference on. IEEE, 2001, 1: 438-445.
- [46] Zhang X, Cui Y, Li D, et al. An adaptive mean shift clustering algorithm based on locality-sensitive hashing[J]. Optik-International Journal for Light and Electron Optics, 2012, 123(20): 1891-1894.
- [47] Solomon J, Crane K, Butscher A, et al. A general framework for bilateral and mean shift filtering[J]. arXiv preprint arXiv:1405.4734, 2014.
- [48] Arias-Castro E, Mason D, Pelletier B. On the estimation of the gradient lines of a density and the consistency of the mean-shift algorithm[J]. Journal of Machine Learning Research, 2016, 17(43): 1-28.
- [49] Mayer A, Greenspan H. An adaptive mean-shift framework for MRI brain segmentation[J]. IEEE Transactions on Medical Imaging, 2009, 28(8): 1238-1250.
- [50] Ekeberg T, Svenda M, Abergel C, et al. Three-dimensional reconstruction of the giant mimivirus particle with an x-ray free-electron laser[J]. Physical review letters, 2015, 114(9): 098102.
- [51] Schroeder W J, Lorensen B, Martin K. The visualization toolkit: an object-oriented approach to 3D graphics[M]. Kitware, 2004.
- [52] Three-dimensional image reconstruction in radiology and nuclear medicine[M]. Springer Science & Business Media, 2013.
- [53] Rowland N C, Miller K J, Starr P A. Three-dimensional accuracy of ECOG strip electrode localization using coregistration of preoperative MRI and intraoperative fluoroscopy[J]. Stereotactic and functional neurosurgery, 2014, 92(1): 8-16.
- [54] Moreland K, Sewell C, Usher W, et al. Vtk-m: Accelerating the visualization toolkit for massively threaded architectures[J]. IEEE computer graphics and applications, 2016, 36(3): 48-58.
- [55] Ayachit U, Geveci B. Scientific data analysis and visualization at scale in VTK/ParaView with

- NumPy[C]//4th Workshop on Python for High Performance and Scientific Computing PyHPC. 2014.
- [56] Martin K, Hoffman B. Mastering CMake: a cross-platform build system: version 3.1[M]. Kitware, 2015.
- [57] Smith P. Software build systems: principles and experience[M]. Addison-Wesley Professional, 2011.
- [58] Kumar A A, Rajan E G. Monotone coloring of 3D MR image slices and extraction of their superficial and volumetric features[C]//Next Generation Computing Technologies (NGCT), 2016 2nd International Conference on. IEEE, 2016: 786-789.
- [59] Jermyn M, Mok K, Mercier J, et al. Intraoperative detection of glioma invasion beyond MRI enhancement with Raman spectroscopy in humans[C]//Optical Biopsy XIII: Toward Real-Time Spectroscopic Imaging and Diagnosis. International Society for Optics and Photonics, 2015, 9318: 93180D.
- [60] Guo L, Hu M, Li Y, et al. Three dimension reconstruction of medical images based on an improved marching cubes algorithm[C]//Biomedical Engineering and Informatics (BMEI), 2013 6th International Conference on. IEEE, 2013: 64-68.

攻读学位期间取得的研究成果

论文:

[1] Fang B W, Zhang X F, Ma Y, et al. DTI images segmentation based on adaptive bandwidth mean shift algorithm[C]//Wavelet Active Media Technology and Information Processing (ICCWAMTIP), 2016 13th International Computer Conference on. IEEE, 2016: 248-251.

[2] 房博文, 张相芬, 马燕, 李传江, 张玉萍 基于改进模糊 C 均值聚类的 DTI 图像分割 (已收录)

专利:

[1] 发明人: 张相芬; 房博文; 马燕; 李传江 发明名称: 一种初始聚类中心选取方法及聚类方法。申请公布号: CN 106570528 A

参加的科研项目:

[1] 2015.09-2016.04 第二十一届校级学生科研重点项目 基于改进的模糊 C 均值聚类的 DTI 图像分割

所获荣誉:

“华为杯”第十三届全国研究生数学建模竞赛二等奖;
上海师范大学“优秀学生”。

致谢

时光荏苒，岁月如梭，最后三年的学生生涯即将结束，三年走来感慨万千，所以不免有些感悟要讲。

首先我要感谢我的导师张相芬，张老师带我迈入了研究生的生涯，为我打开了世界的另一扇门。在学术上，张老师因材施教，并以专业的精神且严谨的态度教导着我，让我慢慢学会去严格要求自己，不断向上。在生活上，张老师对我们关怀有加，拉近了我们的之间距离，在生活给予了我很大的帮助。张老师三年来陪伴我们成长，为我们默默付出了很多，所以我在这想由衷地说声：老师，您辛苦了。

我还要感谢一起学习成长的 535 实验小伙伴们：杨杰，刘利锋，毛丽婷，黄维等，我们在学习的路上互帮互助，感谢你们给我带来的温暖。还有生活在一块的舍友：林建，戚保安，荀俊钦，庄耀贤，感谢你们在生活给我带来的帮助，感谢你们让我生活在这样温暖有爱的家庭之中。

另外还要感谢论文答辩组的各位老师，谢谢您为我提供的宝贵意见。

最后，我要感谢的是我的父母，我的家人，是你们为我的付出，对我的鼓励，才会让我学会成长，追求更好地自己，愿你们的身体健康，生活幸福。

2018 年 4 月